

优化器	核心思想	优点	缺点	典型超参数	适用场景
SGD	沿负梯度方向 固定步长更新	理论收敛性好； 泛化能力上限高	收敛慢；易陷 鞍点；对学习 率极度敏感	<code>lr</code>	学术基准测试；有充足时 间调参追求极致泛化
Momentum SGD	引入速度变量 累积历史梯度 惯性	加速收敛；抑制 梯度震荡	可能冲过最优 解；仍需手动 调 <code>lr</code>	<code>lr, momentum(0.9)</code>	CNN图像分类（ResNet 等）的经典标配
NAG	在"前瞻位 置"而非当前位 置计算梯度	比Momentum 更精准的减速机 制；减少过冲	实现略复杂； 收益相对 Momentum有 限	<code>lr, momentum(0.9)</code>	RNN/LSTM训练；对收敛 稳定性要求高的任务
Adagrad	按参数历史梯 度平方和自适应 缩放学习率	稀疏特征自动获 得大学习率；无 需手动调 <code>lr</code>	学习率单调递 减至零；后期 停止学习	<code>lr, epsilon</code>	NLP词嵌入；稀疏数据推荐 系统
RMSprop	Adagrad的指 数移动平均改 进版	解决Adagrad学 习率衰减问题； 适应非平稳目标	对 <code>epsilon</code> 敏 感；缺乏动量 项	<code>lr, alpha(0.99), epsilon</code>	RNN/LSTM（Hinton推 荐）；早期强化学习
Adam	Momentum + RMSprop 双自 适应	收敛快；对学习 率不敏感；开箱 即用	泛化性有时不 如SGD；内存 开销翻倍	<code>lr(3e-4), betas(0.9,0.999)</code>	Transformer/BERT/GPT； 绝大多数任务的默认首选
AdamW	Adam + 解耦 权重衰减	修复Adam中L2 正则失效问题； 泛化显著提升	内存同Adam； 权重衰减系数 需重新调	<code>lr, betas, weight_decay(0.01~0.1)</code>	LLM预训练/微调；ViT；当 前工业界事实标准
LAMB / LARS	逐层自适应学 习率 + 信任域 约束	支持超大Batch Size训练而不崩 溃	实现复杂；小 Batch无收益	<code>lr, trust_ratio</code>	大规模分布式预训练 （BERT/ResNet大批次）
Sophia / Muon	利用二阶曲率 信息 / 矩阵归 一化	比Adam收敛更 快；token效率 更高	计算/内存开销 大；尚处研究 阶段	<code>lr, gamma</code>	前沿LLM预训练探索；算力 充足时的进阶选项

