

学习二分类指标对比方案

基于 CIFAR-10 数据集，提取 Dog 以及 Cat、Bird、Deer、Horse 共五类数据，构建 Dog（正类） vs Non-Dog（负类）的二分类图像识别任务。通过**控制变量法**设计对比实验，直观观察并深度理解 **AUC (ROC-AUC)** 与 **AUPR (PR-AUC)** 两种评估指标在**样本平衡**与**样本不平衡**分布下的表现差异，验证不平衡处理策略的有效性。

1.数据集构建与预处理

1.1 数据提取与标签映射

从 CIFAR-10（共60,000张，每类6,000张）中提取目标五类，并进行二值化标签映射。

原始类别	映射标签	训练集数量	测试集数量	总计
Dog (狗)	1 (正类)	5,000	1,000	6,000
Cat (猫)	0 (负类)	5,000	1,000	6,000
Bird (鸟)	0 (负类)	5,000	1,000	6,000
Deer (鹿)	0 (负类)	5,000	1,000	6,000
Horse (马)	0 (负类)	5,000	1,000	6,000
负类合计	0	20,000	4,000	24,000

1.2 图像预处理

- RGB 通道 Z-Score 归一化：
 - mean = [0.4914, 0.4822, 0.4465]
 - std = [0.2470, 0.2435, 0.2616]
- 数据增强（仅作用于训练集）：
 - RandomHorizontalFlip(p=0.5)
 - RandomCrop(size=32, padding=4)
 - RandomRotation(degrees=15)

2.对比实验设计

2.1 对比设计

实验组别	训练集构成 (Dog : Non-Dog)	训练集比例	不平衡处理策略	实验目的

实验组别	训练集构成 (Dog : Non-Dog)	训练集比例	不平衡处理策略	实验目的
A组	5,000 : 5,000 (从20k负样本中分层抽样抽5k)	1 : 1	无 (标准 BCE Loss)	建立平衡数据下的指标基线，观察 AUC $\approx$ AUPR。
B组	5,000 : 20,000 (全量使用)	1 : 4	无 (标准 BCE Loss)	观察不平衡如何导致 AUC 虚高，而 AUPR 和 Recall 暴跌。
C组	5,000 : 20,000 (全量使用)	1 : 4	加权 BCE + 重采样	验证不平衡处理策略能否救回 AUPR 和 Recall。

2.2 验证集划分

从各自的训练集中划分出 **20%** 作为验证集，用于 Early Stopping 和阈值调优。

3.模型架构设计

采用 3层卷积 + CBAM注意力 + 全局平均池化(GAP) + 全连接的轻量化架构。

3.1 网络结构

层级序号	模块名称	操作 / 层类型	输入形状 (C×H×W)	输出形状 (C×H×W)	关键参数 / 备注
0	输入层		3 × 32 × 32	3 × 32 × 32	RGB 图像，已做 Z-Score 归一化
1	卷积块 1	Conv2d → BN → ReLU → CBAM	3 × 32 × 32	256 × 32 × 32	kernel=3×3, padding=1, stride=1
2	池化层 1	MaxPool2d	256 × 32 × 32	256 × 16 × 16	kernel=2×2, stride=2
3	卷积块 2	Conv2d → BN → ReLU → CBAM	256 × 16 × 16	256 × 16 × 16	kernel=3×3, padding=1, stride=1
4	池化层 2	MaxPool2d	256 × 16 × 16	256 × 8 × 8	kernel=2×2, stride=2
5	卷积块 3	Conv2d → BN → ReLU → CBAM	256 × 8 × 8	256 × 8 × 8	kernel=3×3, padding=1, stride=1; 无末端池化
6	GAP 层	AdaptiveAvgPool2d + Flatten	256 × 8 × 8	256	输出 1×1 特征图后展平为一维向量

层级序号	模块名称	操作 / 层类型	输入形状 (C×H×W)	输出形状 (C×H×W)	关键参数 / 备注
7	全连接层 1	Dropout → Linear → BN → ReLU → Dropout	256	512	Dropout(p=0.3) → Linear(256→512) → BN → ReLU → Dropout(p=0.2)
8	输出层	Linear	512	1	Linear(512→1), 输出 Logits , 无激活函数

4. 训练策略与超参数配置

4.1 全局超参数（控制变量）

参数	配置	备注
Random Seed	42	固定种子，确保可复现性
Batch Size	64	-
Epochs	100 (上限)	配合早停机制
Optimizer	Adam	-
Initial LR	1e-3	初始学习率
LR Scheduler	<code>ReduceLROnPlateau</code>	patience=7, factor=0.5, 监控 Val F1
Weight Decay	1e-4	L2 正则化
Early Stopping	patience=20	监控指标: Validation F1 Score

4.2 差异化训练策略

配置项	实验 A组	实验 B组	实验 C组
Loss Function	<code>BCEWithLogitsLoss</code> (无权重)	<code>BCEWithLogitsLoss</code> (无权重)	<code>BCEWithLogitsLoss(pos_weight=4.0)</code>
Data Sampler	标准 <code>RandomSampler</code>	标准 <code>RandomSampler</code>	<code>weightedRandomSampler</code> (使Batch内正负≈1:1)

5. 评估指标与阈值调优

5.1 核心评估指标

指标	在不平衡场景下的作用
AUC	衡量整体排序能力。 对不平衡迟钝，容易给出虚高分数。
AUPR	衡量找正类的纯度。 对不平衡极度敏感，真实反映少数类识别能力。
F1 Score	Precision 与 Recall 的调和平均，综合评估。
Recall	真正的 Dog 中找出了多少。


5.2 动态阈值调优（抛弃默认 0.5）

在验证集上遍历阈值 [0.1, 0.2, ..., 0.9]，寻找使 **F1 Score 最大化** 的最优阈值。测试集评估时，必须使用各自在验证集上寻优得到的最优阈值

6.可视化


图表类型	绘制内容
ROC 曲线对比图	将 A、B、C 三组实验的 ROC 曲线绘制于同一坐标系中
PR 曲线对比图	将 A、B、C 三组实验的 PR 曲线绘制于同一坐标系中
混淆矩阵热力图	A、B、C 三组实验各绘制一张独立的混淆矩阵
预测概率分布直方图	

7.结果




可视图	现象	结论
-----	----	----

可视图	现象	结论
ROC 曲线对比图	三条曲线几乎完全重合，AUC 面积差异极小	AUC：对类别不平衡极度迟钝，容易给出虚高分数，掩盖模型在少数类上的严重缺陷。
PR 曲线对比图	B 组曲线向右下方严重塌陷（AUPR 骤降），C 组曲线显著回升并贴近 A 组	AUPR 是：对不平衡极度敏感，精准暴露少数类识别能力的退化；同时验证了加权 BCE + 重采样策略的有效性。



可视图	现象	结论
混淆矩阵热力图	B 组矩阵左下角（FN，漏判的正类 Dog）数值远高于 A、C 组	Recall 暴跌：在不平衡且无干预时，模型倾向于“放弃”识别少数类以换取整体 Loss 最低，导致大量正类被误判为负类。



可视图	现象	结论
预测概率分布直方图	B 组中正类（Dog）的概率分布被严重“向左挤压”	阈值失效根本原因：不平衡导致模型对正类的置信度系统性偏低，默认 0.5 阈值切分会漏掉大量 Dog，必须通过动态阈值调优来捞回正类。

FINAL RESULTS SUMMARY

Experiment	AUC	AUPR	F1	Recall	Threshold
A_Balanced	0.9495	0.8601	0.7344	0.8750	0.73
B_Imbalanced	0.9506	0.8822	0.7960	0.7470	0.71
C_Fixed	0.9560	0.8922	0.8090	0.7880	0.90

AUPR没有暴跌根本原因在于：1:4 的不平衡比例对于 AUPR 指标来说“太温和了”，不足以触发理论上的“AUPR 塌陷”；同时 B 组因负样本量大，模型学到了更鲁棒的负类边界，反而提升了 Precision。

核心矛盾解答：为什么 B 组 AUPR (0.88) > A 组 (0.86)

预期的“B组PR曲线向右下方严重塌陷”通常发生在 1:10、1:50 甚至 1:100 的极端不平衡场景中。该实验中：

- **基线先验概率较高**：B 组测试集正类占比为 20%。这意味着即使是一个完全随机猜测的模型，其 Precision 基线也是 0.2，而非极端不平衡下的 0.01。AUPR 对这种程度的不平衡**不够敏感**。
- B 组使用了全量 20,000 张负样本训练，而 A 组仅用了 5,000 张。在 CIFAR-10 这种细粒度分类任务中，更多的负样本意味着模型见过更多 Cat/Bird/Deer/Horse 的变体，负类特征空间被建模得更完整。
 - **结果**：B 组的 False Positive（误报）显著减少 → **Precision 提升** → 抵消了 Recall 下降带来的 AUPR 损失 → 最终 AUPR 反而略高。
- **A 组的“欠拟合”风险**：A 组虽然平衡，但负样本仅 5k，可能未覆盖所有负类模式，导致测试时遇到未见过的负类变体产生误判，拉低了 Precision 和 AUPR。

8.展望

可将CIFAR-10中的10类数据全部应用，替代原先的5类。即1:4的不平衡扩大到1:9的不平衡，进而观察B组是否AUPR实现暴跌的效果。