

一张图像等于 16×16 个词：用于大规模图像识别的 Transformer

摘要

虽然 Transformer 架构已经成为自然语言处理（NLP）任务中的事实标准，但它在计算机视觉领域的应用仍然比较有限。在计算机视觉中，注意力机制（Attention）通常与卷积神经网络（CNN）结合使用，或者用注意力机制替代 CNN 中的某些组件，同时仍然保留 CNN 的整体结构。我们证明，对 CNN 的依赖并不是必要的。一个纯粹的 Transformer，只需要直接作用于由图像切分得到的图像块

（image patches）序列，就能够在图像分类任务中取得非常好的效果。当在大量数据上进行预训练，并迁移到多个中等规模或小规模的图像识别基准数据集（如 ImageNet、CIFAR-100、VTAB 等）时，Vision Transformer（ViT）相比当前最先进的卷积神经网络（CNN），能够取得优异的性能，同时训练所需的计算资源显著更少。

1. 引言：

基于自注意力机制（Self-attention）的架构，尤其是 Transformers (Vaswani et al., 2017)，已经成为自然语言处理（NLP）领域中最主要的模型选择。主流的方法是在大规模文本语料库上进行预训练，然后在较小的、针对特定任务的数据集上进行微调（Devlin 等人，2019）。得益于 Transformer 的计算效率和可扩展性，现在已经能够训练出规模前所未有的模型，其参数量超过 1000 亿（Brown 等人，2020；Lepikhin 等人，2020）。随着模型和数据集规模不断扩大，模型性能仍然没有表现出饱和的迹象。

然而，在计算机视觉领域，卷积神经网络架构（CNN）仍然占据主导地位。（LeCun et al., 1989；Krizhevsky et al., 2012；He et al., 2016）。受到自然语言处理（NLP）领域成功经验的启发，许多研究尝试将类似 CNN 的架构与自注意力机制（self-attention）相结合（Wang et al., 2018；Carion et al., 2020），其中一些研究甚至尝试完全用自注意力机制取代卷积操作（Ramachandran et al., 2019；Wang et al., 2020a）。后者的模型虽然在理论上具有较高的计算效率，但由于采用了特殊设计的注意力模式（specialized attention patterns），目前还无法在现代硬件加速器上实现有效的规模化训练。因此，在大规模图像识别任务中，经典的 ResNet 类架构仍然处于最先进水平（state of the art, SOTA）（Mahajan et al., 2018；Xie et al., 2020；Kolesnikov et al., 2020）。

受到 Transformer 在自然语言处理（NLP）领域扩展规模方面取得成功的启发，我们尝试将一个标准的 Transformer 直接应用于图像，并且尽可能少地对其进行修改。具体来说，我们将一张图像划分成若干个图像块（patches），然后将这些图像块经过线性映射得到的嵌入向量序列（sequence of linear embeddings）作为 Transformer 的输入。在 NLP 应用中，输入通常是一个个 token（词）；而在这里，图像块（image patches）被视为与 NLP 中的 token（单词）相同的基本输入单位。我们采用监督学习（supervised learning）的方式，在图像分类任务上对模型进行训练。

当在 ImageNet 这类中等规模的数据集上进行训练、且没有采用强正则化时，这些模型的准确率会比相同规模的 ResNet 低几个百分点。这种看似令人沮丧的结果其实是可以预期的：Transformer 缺少 CNN 所固有的一些归纳偏置（inductive biases），例如平移等变性（translation equivariance）和局部性（locality）。因此，当训练数据量不足时，Transformer 的泛化能力较差。

然而，如果模型在更大规模的数据集（包含 1,400 万至 3 亿张图像）上进行训练，情况就会发生变化。我们发现，大规模训练能够胜过归纳偏置的影响。我们的视觉 Transformer（Vision Transformer, ViT）在足够大的数据规模上进行预训练，并迁移到数据量较少的任务时，能够取得非常出色的效果。当在公开的 ImageNet-21k 数据集或内部的 JFT-300M 数据集上进行预训练后，ViT 在多个图像识别基准测试中都能够接近甚至超过当前最先进的水平。特别是，最佳模型在 ImageNet 上达到了 88.55% 的准确率，在 ImageNet-Real 上达到了 90.72%，在 CIFAR-100 上达到了 94.55%，并在包含 19 个任务的 VTAB 基准测试中达到了 77.63% 的准确率。

2. 准备工作

Transformer 最初由 Vaswani 等人（2017）提出，用于机器翻译，此后逐渐成为许多自然语言处理（NLP）任务中的最先进方法。基于 Transformer 的大型模型通常会先在大规模语料库上进行预训练，然后针对具体任务进行微调：BERT（Devlin 等，2019）采用去噪自监督预训练任务，而 GPT 系列工作则将语言建模作为其预训练任务（Radford 等，2018；2019；Brown 等，2020）。

直接将自注意力机制应用于图像意味着每个像素都需要关注其他所有像素。由于其计算成本随着像素数量呈平方增长，因此无法扩展到实际应用中的较大尺寸输入。为此，在将 Transformer 应用于图像处理时，过去人们尝试了多种近似方法。Parmar 等人（2018）没有让每个查询像素进行全局注意，而是仅在其局部邻域内应用自注意力机制。这类局部多头点积自注意力模块可以完全替代卷积操作（Hu 等，2019；Ramachandran 等，2019；Zhao 等，2020）。另一类研究中的 Sparse Transformer（Child 等，2019）采用可扩展的全局自注意力近似方法，使其能够应用于图像。另一种扩展注意力机制的方法是以不同大小的区域块为单位进行注意力计算（Weissenborn 等，2019），极端情况下甚至只沿着单独的坐标轴进行注意力计算（Ho 等，2019；Wang 等，2020a）。这些专门设计的注意力架构中，有许多在计算机视觉任务上取得了很有前景的结果，但要在硬件加速器上高效实现，通常需要复杂的工程设计。

与我们的工作最为相关的是 Cordonnier 等人（2020）提出的模型。该模型从输入图像中提取大小为 2×2 的图像块（patch），然后在其基础上应用完整的自注意力机制。该模型与 ViT 非常相似，但我们的工作进一步证明了，通过大规模预训练，原始的 Transformer（vanilla Transformer）可以与当前最先进的 CNN 相媲美，甚至取得更好的效果。此外，Cordonnier 等人（2020）采用了较小的 2×2 像素图像块，这使得该模型只能应用于低分辨率图像，而我们的模型则同样能够处理中等分辨率的图像。

此外，人们也对将卷积神经网络（CNN）与各种形式的自注意力机制相结合产生了浓厚的兴趣，例如，在图像分类中通过增强特征图来引入自注意力机制（Bello 等，2019），或者进一步利用自注意力机制处理 CNN 的输出，并将其应用于目标检测（Hu 等，2018；Carion 等，2020）、视频处理（Wang 等，2018；Sun 等，2019）、图像分类（Wu 等，2020）、无监督目标发现（Locatello 等，2020）以及统一的文本-视觉任务（Chen 等，2020c；Lu 等，2019；Li 等，2019）。

另一个近期相关的模型是 Image GPT (iGPT) (Chen 等, 2020a), 该模型在降低图像分辨率和颜色空间后, 将 Transformer 应用于图像像素。该模型以生成模型的方式进行无监督训练, 得到的图像表示随后可以通过微调或线性探测 (linear probing) 用于分类性能评估, 并在 ImageNet 上取得了最高 72% 的准确率。

我们的工作也属于近年来越来越多研究中的一部分, 这些研究致力于探索在比标准 ImageNet 数据集更大规模的数据上进行图像识别。利用额外的数据来源, 可以在标准基准测试中取得当前最先进的结果 (Mahajan 等, 2018; Touvron 等, 2019; Xie 等, 2020)。此外, Sun 等人 (2017) 研究了 CNN 的性能如何随着数据集规模的增大而变化, 而 Kolesnikov 等人 (2020) 和 Djolonga 等人 (2020) 则对从 ImageNet-21k 和 JFT-300M 等大规模数据集进行 CNN 迁移学习进行了实证研究。我们的工作同样关注后面提到的这两个数据集, 但与以往工作所采用的基于 ResNet 的模型不同, 我们使用 Transformer 进行训练。




图 1: 模型概览。我们将一幅图像划分为固定大小的图像块 (patch), 分别对每个图像块进行线性嵌入 (linear embedding), 然后加入位置嵌入 (position embedding), 并将得到的向量序列输入一个标准的 Transformer 编码器。为了实现图像分类, 我们采用标准的方法, 在序列中加入一个额外的、可学习的“分类标记 (classification token)”。图中的 Transformer 编码器示意图参考了 Vaswani 等人 (2017) 的设计。

3. 方法

在模型设计方面, 我们尽可能遵循原始 Transformer (Vaswani 等, 2017) 的设计。这样一种有意保持简单的设计方式, 其优势在于, 可以几乎直接使用已经具备良好扩展性的 NLP Transformer 架构及其高效实现, 而无需进行太多修改。

3.1 视觉 Transformer (ViT)

模型的整体结构如图 1 所示。标准 Transformer 的输入是一维的 token 嵌入序列。为了处理二维图像，我们将图像 $x \in \mathbb{R}^{H \times W \times C}$ 重塑为一系列展平的二维图像块 $x_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$ ，其中， (H,W) 表示原始图像的分辨率， C 表示图像的通道数， (P,P) 表示每个图像块的分辨率，而 $N = HW/P^2$ 表示最终得到的图像块数量，同时也作为 Transformer 的有效输入序列长度。Transformer 在其所有层中都使用固定大小的潜在向量维度 D ，因此，我们首先将图像块展平，然后通过一个可训练的线性投影将其映射到 D 维空间（公式 1）。我们将这一线性投影的输出称为图像块嵌入（patch embeddings）。

与 BERT 的 [class] token 类似，我们在图像块嵌入序列的开头添加一个可学习的嵌入向量 $(z_0 = x_{\text{class}} z_0^0 = x_{\text{class}})$ ，该向量经过 Transformer 编码器后在输出端的状态 $(z_L z_L^0)$ 作为图像的表示 y （公式 4）。在预训练和微调阶段，我们都会在 $z_L z_L^0$ 上连接一个分类头（classification head）。在预训练阶段，分类头由一个包含一个隐藏层的 MLP 实现；而在微调阶段，则使用一个单独的线性层来实现。

我们将位置嵌入（position embeddings）添加到图像块嵌入（patch embeddings）中，以保留图像的位置信息。由于我们没有观察到使用更先进的、能够感知二维空间信息的位置嵌入能够带来显著的性能提升（附录 D.4），因此采用了标准的可学习一维位置嵌入（1D position embeddings）。最终得到的嵌入向量序列作为 Transformer 编码器的输入。

Transformer 编码器（Vaswani 等，2017）由多头自注意力（Multi-Headed Self-Attention, MSA，见附录 A）层和 MLP 模块交替组成（公式 2、3）。在每个模块之前都应用层归一化（LayerNorm, LN），并在每个模块之后加入残差连接（Wang 等，2019；Baevski & Auli, 2019）。MLP 包含两个全连接层，并使用 GELU 作为非线性激活函数。

$$z_0 = [x_{\text{class}}; x_p^1 E; x_p^2 E; \dots; x_p^N E] + E_{\text{pos}}, \quad E \in \mathbb{R}^{(P^2 \cdot C) \times D}, \quad E_{\text{pos}} \in \mathbb{R}^{(N+1) \times D} \quad (1)$$

$$z'_\ell = \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1}, \quad \ell = 1 \dots L \quad (2)$$

$$z_\ell = \text{MLP}(\text{LN}(z'_\ell)) + z'_\ell, \quad \ell = 1 \dots L \quad (3)$$

$$y = \text{LN}(z_L^0) \quad (4)$$

归纳偏置 (Inductive bias)。 我们注意到，与 CNN 相比，Vision Transformer 所具有的图像特定归纳偏置要少得多。在 CNN 中，局部性、二维邻域结构以及平移等变性都被内置于整个模型的每一层中。而在 ViT 中，只有 MLP 层具有局部性和平移等变性，自注意力层则是全局的。二维邻域结构的使用非常有限：一开始通过将图像划分为图像块（patches）来使用二维结构，而在微调阶段，则用于调整不同分辨率图像的位置嵌入（如下文所述）。除此之外，在模型初始化时，位置嵌入本身并不包含关于图像块二维位置的信息，因此，图像块之间的所有空间关系都必须从头开始学习。

混合架构 (Hybrid Architecture)。 除了直接使用原始图像块之外，还可以利用 CNN 的特征图来构成输入序列（LeCun 等，1989）。在这种混合模型中，将图像块嵌入投影 E （公式 1）应用于从 CNN 特征图中提取的图像块。作为一种特殊情况，图像块的空间尺寸可以为 $1 \times 11 \times 1$ ，这意味着只需将特征图的空间维度展平，然后将其投影到 Transformer 的维度，即可得到输入序列。分类输入嵌入

(classification input embedding) 和位置嵌入 (position embeddings) 则按照前文所述的方式添加。

3.2 微调与更高分辨率

通常，我们先在大型数据集上对 ViT 进行预训练，然后将其微调到规模较小的下游任务上。为此，我们移除预训练阶段的预测头，并添加一个零初始化的 $D \times KD \times K$ 前馈层，其中 K 表示下游任务中的类别数量。在比预训练阶段更高的分辨率下进行微调通常是有益的 (Touvron 等, 2019; Kolesnikov 等, 2020)。当输入更高分辨率的图像时，我们保持图像块 (patch) 的大小不变，这会导致有效的输入序列长度变大。Vision Transformer 可以处理任意长度的输入序列 (受内存限制)，但是，预训练的位置嵌入可能不再具有合理的意义。因此，我们根据位置嵌入在原始图像中的位置，对预训练的位置嵌入进行二维插值 (2D interpolation)。需要注意的是，分辨率调整和图像块提取是仅有的两个环节，在这两个环节中，我们人为地向 Vision Transformer 注入了关于图像二维结构的归纳偏置。

4. 实验

我们评估了 ResNet、Vision Transformer (ViT) 以及混合架构 (hybrid) 的表示学习能力。为了了解不同模型对数据量的需求，我们在不同规模的数据集上进行预训练，并在多个基准任务上进行评估。在考虑模型预训练的计算成本时，ViT 表现得非常出色：以更低的预训练成本，在大多数图像识别基准测试中达到了当前最先进的水平。最后，我们还进行了一项小规模(self-supervised)的自监督学习实验，结果表明，自监督 ViT 具有良好的发展前景。

4.1 实验设置

数据集。为了探索模型的可扩展性，我们使用了 ILSVRC-2012 ImageNet 数据集，该数据集包含 1,000 个类别和 130 万张图像 (下文简称 ImageNet)；它的超集 ImageNet-21k 包含 21,000 个类别和 1,400 万张图像 (Deng 等, 2009)；以及 JFT 数据集 (Sun 等, 2017)，包含 18,000 个类别和 3.03 亿张高分辨率图像。按照 Kolesnikov 等人 (2020) 的方法，我们针对下游任务的测试集，对预训练数据集进行了去重处理。随后，我们将基于这些数据集训练得到的模型迁移到多个基准任务上进行评估，包括使用原始验证集标签和清理后的 Real 标签的 ImageNet (Beyer 等, 2020)、CIFAR-10/100 (Krizhevsky, 2009)、Oxford-IIIT Pets (Parkhi 等, 2012) 以及 Oxford Flowers-102 (Nilsback & Zisserman, 2008)。对于这些数据集，数据预处理过程遵循 Kolesnikov 等人 (2020) 的方法。

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

我们还在包含 19 个任务的 VTAB 分类基准（VTAB classification suite）上进行了评估（Zhai 等，2019b）。VTAB 用于评估模型在多种不同任务上的小数据迁移能力，每个任务仅使用 1,000 个训练样本。这些任务被划分为三组：Natural（自然类）——包括前面提到的 Pets、CIFAR 等自然图像任务；Specialized（专业类）——包括医学图像和卫星图像等任务；以及 Structured（结构类）——包括需要进行几何理解的任务，例如定位（localization）。

模型变体（Model Variants）。我们以 BERT（Devlin 等，2019）所采用的模型配置为基础设计 ViT，其具体配置总结于表 1 中。“Base”和“Large”模型直接采用 BERT 中的对应版本，并在此基础上增加了更大的“Huge”模型。下文中，我们使用简写来表示模型规模和输入图像块的大小。例如，ViT-L/16 表示采用“Large”规模、输入图像块大小为 $16 \times 16 \times 16$ 的模型。需要注意的是，Transformer 的序列长度与图像块大小的平方成反比，因此，图像块越小的模型，其计算成本越高。

对于基线 CNN，我们采用 ResNet（He 等，2016），但将其中的批归一化（Batch Normalization）层（Ioffe & Szegedy，2015）替换为组归一化（Group Normalization）（Wu & He，2018），并使用标准化卷积（standardized convolutions）（Qiao 等，2019）。这些修改能够改善模型的迁移性能（Kolesnikov 等，2020），因此我们将修改后的模型称为 ResNet（BiT）。对于混合架构，我们将中间特征图输入 ViT，并将图像块大小设置为“1 个像素”。为了研究不同序列长度的影响，我们采用两种方式：（i）取标准 ResNet50 的第 4 阶段（stage 4）的输出；或者（ii）移除第 4 阶段，将相同数量的层放入第 3 阶段（同时保持网络总层数不变），然后取扩展后的第 3 阶段的输出。方案（ii）会使序列长度增加 4 倍，同时也使 ViT 模型的计算成本更高。

训练与微调（Training & Fine-tuning）。我们使用 Adam（Kingma & Ba，2015）训练所有模型，包括 ResNet，其中 $\beta_1 = 0.9$ 、 $\beta_2 = 0.999$ ，批大小（batch size）为 4096，并采用较高的 0.1 权重衰减（weight decay）。我们发现，这种设置有利于所有模型的迁移学习（附录 D.1 表明，与通常的做法不同，在我们的实验设置中，Adam 在 ResNet 上的表现略优于 SGD）。我们采用线性学习率预热（linear learning rate warmup）和学习率衰减（decay），具体细节见附录 B.1。对于微调，我们对所有模型使用带动量的 SGD，批大小为 512，具体见附录 B.1.1。对于表 2 中的 ImageNet 结果，我们使用更高的分辨率进行微调：ViT-L/16 使用 512 的分辨率，ViT-H/14 使用 518 的分辨率；同时还采用了 Polyak & Juditsky（1992）的参数平均方法，平均系数为 0.9999（Ramachandran 等，2019；Wang 等，2020b）。

评价指标（Metrics）。我们在下游数据集上通过少样本（few-shot）准确率或微调准确率（fine-tuning accuracy）来报告实验结果。微调准确率表示模型在相应数据集上完成微调之后所达到的性能。少样本准确率则通过求解一个正则化最小二乘回归问题得到：将一部分训练图像经过冻结的模型

得到的表示映射到目标向量 $-1, 1K\{-1, 1\}^K$ 。这种方法可以得到一个闭式精确解。虽然我们的主要关注点是微调后的性能，但有时会使用线性少样本准确率进行快速的即时评估，因为在某些情况下进行完整的微调计算成本过高。

4.2 与当前最先进方法的比较

首先，我们将最大的两个模型——ViT-H/14 和 ViT-L/16——与文献中当前最先进的 CNN 模型进行比较。第一个比较对象是 Big Transfer (BiT) (Kolesnikov 等, 2020)，该方法使用大型 ResNet 进行监督式迁移学习。第二个比较对象是 Noisy Student (Xie 等, 2020)，它是一种大型 EfficientNet，采用半监督学习方法，在去除标签的 ImageNet 和 JFT-300M 数据集上进行训练。目前，Noisy Student 在 ImageNet 上取得了最先进的结果，而在本文报告的其他数据集上，BiT-L 达到了最先进的水平。所有模型均使用 TPUv3 硬件进行训练，我们报告了每个模型预训练所使用的 TPUv3 核心天数 (TPUv3-core-days)，即用于训练的 TPU v3 核心数量 (每个芯片包含 2 个核心) 乘以训练所花费的天数。表 2 展示了实验结果。在 JFT-300M 上进行预训练的较小模型 ViT-L/16 在所有任务上的表现都超过了同样在该数据集上进行预训练的 BiT-L，同时训练所需的计算资源却显著更少。更大的 ViT-H/14 进一步提升了性能，尤其是在更具挑战性的数据集上，例如 ImageNet、CIFAR-100 以及 VTAB 基准中的各项任务。有趣的是，这

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet Real	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

表 2：在常用图像分类基准测试上与当前最先进方法的比较。我们报告了模型准确率的均值和标准差，该结果是对 3 次微调实验得到的结果取平均。基于 JFT-300M 数据集进行预训练的 Vision Transformer 模型在所有数据集上的表现都超过了基于 ResNet 的基线模型，同时预训练所需的计算资源显著更少。在规模较小的公开 ImageNet-21k 数据集上进行预训练的 ViT 同样取得了良好的表现。* Touvron 等人 (2020) 报告了一个略有提升的 88.5% 结果。




Figure 2: Breakdown of VTAB performance in *Natural*, *Specialized*, and *Structured* task groups.

该模型在预训练过程中所需的计算资源仍然显著少于此前的最先进方法（state of the art）。不过，我们需要指出，预训练效率不仅可能受到模型架构选择的影响，还可能受到训练策略（training schedule）、优化器（optimizer）、权重衰减（weight decay）等其他参数的影响。我们将在第 4.4 节中针对不同架构进行受控实验，以研究模型性能与计算成本之间的关系。最后，在公开的 ImageNet-21k 数据集上进行预训练的 ViT-L/16 模型在大多数数据集上同样表现良好，同时预训练所需的资源更少：使用标准的云端 TPuv3、8 个核心，大约 30 天即可完成训练。

图 2 将 VTAB 中的任务按照所属类别进行划分，并将其与该基准测试中此前的最先进方法进行比较，包括 BiT、ViVi——一种在 ImageNet 和 YouTube 数据上进行联合训练的 ResNet（Tschannen 等，2020），以及 S4L——一种在 ImageNet 上结合监督学习与半监督学习的方法（Zhai 等，2019a）。在 Natural 和 Structured 两类任务上，ViT-H/14 的表现优于 BiT-R152x4 以及其他方法；而在 Specialized 类任务上，排名前两位的模型表现较为接近。

4.3 预训练数据需求

Vision Transformer 在大型 JFT-300M 数据集上进行预训练时表现良好。与 ResNet 相比，Vision Transformer 所具有的视觉归纳偏置（inductive biases）更少，那么数据集的规模究竟有多重要呢？我们进行了两组实验。首先，我们在规模逐渐增大的数据集上对 ViT 模型进行预训练：ImageNet、ImageNet-21k 和 JFT-300M。为了提升模型在较小数据集上的性能，我们对三个基本的正则化参数进行了优化——权重衰减（weight decay）、Dropout 和标签平滑（label smoothing）。图 3 展示了模型在微调到 ImageNet 后的结果（其他数据集上的结果见表 5）²。当在最小的数据集 ImageNet 上进行预训练时，即使采用了适度的正则化，ViT-Large 模型的表现仍然不如 ViT-Base 模型；当使用 ImageNet-21k 进行预训练时，两者的性能变得较为接近；只有在 JFT-300M 上进行预训练时，我们才能看到更大规模模型所带来的全部优势。图 3 还展示了模型性能范围。BiT 的 CNN 模型在 ImageNet 上的表现优于 ViT，但随着数据集规模的增大，ViT 逐渐超过了 BiT。




图 3: 迁移到 ImageNet (Transfer to ImageNet)。当在较小的数据集上进行预训练时, 大规模 ViT 模型的表现不如 BiT ResNet (阴影区域表示); 但是, 当在更大的数据集上进行预训练时, ViT 大模型展现出了明显优势。同样地, 随着数据集规模的增加, 更大规模的 ViT 模型变体会超过较小规模的模型。




图 4: ImageNet 上的线性少样本评估 (Linear few-shot evaluation) 与预训练数据规模之间的关系。在较小规模的预训练数据集上, ResNet 的表现更好; 但是, 与 ViT 相比, ResNet 更早达到性能瓶颈 (plateau)。随着预训练数据规模的增大, ViT 能够获得更好的性能, 并逐渐超过 ResNet。ViT-b 表示隐藏维度 (hidden dimensions) 均缩小一半的 ViT-B 模型。




图 5: 不同架构的预训练计算成本与性能之间的关系: Vision Transformer、ResNet 和混合架构 (hybrids)。在相同的计算预算下, Vision Transformer 通常能够超过 ResNet 的性能。混合架构在较小规模的模型中优于纯 Transformer 模型, 但随着模型规模增大, 这种性能差距逐渐消失。

其次，我们在随机抽取的 9M、30M 和 90M 数据子集以及完整的 JFT-300M 数据集上训练模型。对于规模较小的数据子集，我们不进行额外的正则化，并在所有设置中使用相同的超参数。这样，我们评估的是模型本身的内在特性，而不是正则化所带来的影响。不过，我们仍然采用提前停止（early stopping），并报告训练过程中所达到的最佳验证集准确率。为了节省计算资源，我们不使用完整微调后的准确率，而是报告少样本线性准确率（few-shot linear accuracy）。结果如图 4 所示。在较小的数据集上，对于计算成本相近的模型，Vision Transformer 比 ResNet 更容易出现过拟合。例如，ViT-B/32 的训练速度略快于 ResNet50，但在 9M 数据子集上的表现明显更差，而在 90M 及更大的数据子集上则表现更好。ResNet152x2 和 ViT-L/16 也呈现出相同的情况。这一结果进一步支持了这样的直觉：卷积归纳偏置（convolutional inductive bias）对于较小的数据集是有帮助的；但对于更大的数据集而言，直接从数据中学习相关模式已经足够，甚至能够带来更好的效果。

总体而言，ImageNet 上的少样本结果（图 4）以及 VTAB 上的低数据量结果（表 2）都表明，Vision Transformer 在极低数据量的迁移学习场景中具有较好的应用潜力。进一步分析 ViT 的少样本特性，是未来一个值得研究的方向。

4.4 缩放实验（SCALING STUDY）

我们从 JFT-300M 数据集出发，通过评估模型的迁移性能，对不同模型进行了受控的规模扩展实验（scaling study）。在这一设置下，数据集规模并不是限制模型性能的瓶颈，因此我们主要评估各模型的性能与其预训练计算成本之间的关系。实验中的模型包括：7 个 ResNet 模型，即 R50x1、R50x2、R101x1、R152x1、R152x2，它们均预训练 7 个 epoch；此外，还有 R152x2 和 R200x3，它们预训练 14 个 epoch；6 个 Vision Transformer 模型，即 ViT-B/32、B/16、L/32、L/16，它们预训练 7 个 epoch，此外还有 L/16 和 H/14，它们预训练 14 个 epoch；以及 5 个混合模型（hybrid），即 R50+ViT-B/32、B/16、L/32、L/16，它们预训练 7 个 epoch，此外还有 R50+ViT-L/16，它预训练 14 个 epoch。对于混合模型而言，模型名称末尾的数字并不表示图像块（patch）的大小，而是表示 ResNet 主干网络（backbone）的总下采样比例。

图 5 展示了模型的迁移性能与总预训练计算量之间的关系（关于计算成本的详细信息见附录 D.5）。每个模型的详细结果见附录中的表 6。我们可以观察到一些规律。首先，在性能与计算成本之间的权衡方面，Vision Transformer 优于 ResNet。为了达到相同的性能，ViT 所需的计算量大约减少了 2~4 倍（在 5 个数据集上的平均结果）。其次，在较小的计算预算下，混合模型的性能略优于 ViT，但随着模型规模增大，这种差异逐渐消失。这一结果有些出人意料，因为人们可能会认为卷积所提供的局部特征处理能力在任何模型规模下都能够帮助 ViT。第三，在我们实验的规模范围内，Vision Transformer 的性能似乎尚未达到饱和，这也为未来进一步扩大模型规模提供了研究动机。

4.5 Vision Transformer 的内部分析（INSPECTING VISION TRANSFORMER）

为了初步理解 Vision Transformer 如何处理图像数据，我们分析了其内部表示。Vision Transformer 的第一层会将展平后的图像块（patches）线性投影到一个低维空间中（公式 1）。图 7（左）展示了所学习的嵌入滤波器（embedding filters）的前几个主成分（principal components）。这些成分类似于一种合理的基函数（basis functions），可以用于表示每个图像块内部的细粒度结构。

在线性投影之后，模型会将一个可学习的位置嵌入（position embedding）添加到图像块的表示中。图 7（中）表明，模型会通过位置嵌入之间的相似性来编码图像中的距离信息，即距离较近的图像块往往具有更加相似的位置嵌入。此外，还可以观察到行—列结构：位于同一行或同一列的图像块具有相似的嵌入表示。最后，对于较大的图像块网格，有时还可以观察到一种正弦结构（sinusoidal structure）（见附录 D）。位置嵌入能够学习表示二维图像的拓扑结构，这也解释了为什么手工设计的、具有二维感知能力的位置嵌入变体并不能带来性能提升（见附录 D.4）。




图 6：从输出 token 到输入空间的注意力（attention）示例。具体细节请参见附录 D.7。

自注意力机制使 ViT 能够在较低层中整合整幅图像的信息。自注意力机制使得 Vision Transformer（ViT）即使在网络的较低层，也能够整合来自整张图像的信息。我们研究了网络在多大程度上利用了这一能力。具体来说，我们根据注意力权重（attention weights）计算了信息在图像空间中被整合时所跨越的平均距离（图 7，右）。这种“注意力距离（attention distance）”类似于 CNN 中的感受野大小（receptive field size）。

我们发现，一些注意力头（attention heads）在网络的最低层就已经关注了图像的大部分区域，这表明模型确实利用了全局信息整合的能力。与此同时，其他一些注意力头在较低层中始终保持较小的注意力距离。这种高度局部化的注意力现象，在先经过 ResNet 再输入 Transformer 的混合模型（hybrid models）中并不明显（图 7，右），这说明局部注意力可能发挥了与 CNN 中早期卷积层类似的作用。此外，随着网络深度增加，注意力距离也逐渐增大。从整体来看，我们发现模型会关注那些对于分类任务具有语义相关性的图像区域（图 6）。

4.6 自监督学习（SELF-SUPERVISION）

Transformer 在自然语言处理（NLP）任务中展现出了出色的性能。然而，它们的成功不仅来源于优秀的可扩展性，还得益于大规模的自监督预训练（Devlin 等，2019；Radford 等，2018）。我们也对掩码图像块预测（masked patch prediction）这一自监督学习方法进行了初步探索，该方法模仿了 BERT 中使用的掩码语言模型（masked language modeling）任务。在采用自监督预训练后，较小规模的 ViT-B/16 模型在 ImageNet 上达到了 79.9% 的准确率，相比从头训练（training from scratch）提升了约 2%，但仍然比监督式预训练低约 4%。更多细节见附录 B.1.2。我们将对比学习预训练（contrastive pre-training）方向的探索留待未来工作（Chen 等，2020b；He 等，2020；Bachman 等，2019；Hénaff 等，2020）。




图7：左图：ViT-L/32 对 RGB 值进行初始线性嵌入时所使用的滤波器。中图：ViT-L/32 的位置嵌入相似度。图中的每个小方格表示指定行和列位置的图像块的位置嵌入与其他所有图像块的位置嵌入之间的余弦相似度。右图：不同注意力头和网络深度对应的注意区域大小。每个点表示某一层 16 个注意力头中的一个注意力头在所有图像上的平均注意力距离。具体细节请参见附录 D.7。

5. 结论（CONCLUSION）

我们探索了将 Transformer 直接应用于图像识别任务的方法。不同于以往在计算机视觉中使用自注意力机制的工作，我们除了最初的图像块（patch）提取步骤之外，并没有向模型架构中引入任何针对图像的特定归纳偏置（image-specific inductive biases）。相反，我们将图像表示为一个由图像块组成的序列，并使用自然语言处理（NLP）中所采用的标准 Transformer 编码器对其进行处理。这种简单但具有良好扩展性的策略，在结合大规模数据集进行预训练后，取得了出乎意料的良好效果。因此，Vision Transformer（ViT）在许多图像分类数据集上达到了或超过了当前最先进（state-of-the-art）的方法，同时预训练成本相对较低。

虽然这些初步结果令人鼓舞，但仍然存在许多挑战。第一个挑战是将 ViT 应用于其他计算机视觉任务，例如目标检测（detection）和图像分割（segmentation）。我们的实验结果以及 Carion 等人（2020）的研究表明，这种方法具有很大的发展潜力。另一个挑战是继续探索自监督预训练方法（self-supervised pre-training methods）。我们的初步实验表明，自监督预训练能够带来性能提升，但自监督预训练与大规模监督式预训练之间仍然存在较大的差距。最后，进一步扩大 ViT 的模型规模，很可能会带来更高的性能。