

AlexNet模型笔记

1. 数据集

2010虽然测试集有标签，但是太旧了，现在都使用12作为标准

项目	AlexNet 使用的数据
数据集	ImageNet 的子集ILSVRC-2012
类别数	1000 类
训练集	约 120 万张
验证集	5 万张
测试集（标签未公开）	10万张
图片类型	RGB 彩色自然图像
原始输入尺寸	H×W×3（大小不一）
输入尺寸	224×224×3
输入维度	224×224×3=150528个像素值
输出维度	1000（softmax 概率）
标注类型	图像分类标注




1.什么是完整分割标注组成的图像？

图像（普通）分类标注VS完整分割标注

图像分类标注：图片里有狗，标签是狗

完整分割标注：每一个像素都有自己的类别



1.1 数据预处理

CNN要求固定输入尺寸

先把原始图片缩放到短边为256，然后从中心位置裁剪到 256×256



2.为什么从每个像素中减去训练集上的平均活动值（即均值）？【即减去一个，平均后的像素图】

让输入数据以0为中心，方便神经网络学习，**准**

2.1为什么0中心化有帮助？

因为神经网络训练依赖梯度下降。


输入全部为正：权重更新方向容易一致。

导致：梯度更新效率低；收敛慢；参数调整困难

输入有正，负值：梯度方向更加平衡；训练更稳定。

2.2咋影响的？

根据链式公式以及反向w更新公式，如果都是正的，要变都是一个方向变



2. 模型（还有个变体模型）

2.1 ReLU




4.啥叫饱和，不饱和非线性函数？

有没有单界（增加看上界，减少看下届）

饱和：有界；不饱和：无界

w更新，会有个变换的单调性，如果随着w变量单调变，函数趋向于一个值不变就没有更新的必要了



显然不饱和训练速度快

数据归一化，也就是变量等比例减少，可以防止饱和发生，但ReLU不饱和，可以不进行归一化



ReLU为什么叫修正线性单元？

ReLU只将负数部分的线性修正为0，正数部分没修正，所以叫修正不叫改



什么叫做模型的泛化能力？

模型在没有见过的新数据上表现良好的能力

也就是：模型不是只记住训练数据，而是学到了数据背后的规律，可以处理新的情况



了解的对比度归一化之后接局部平均池化模型

对比度归一化是一种图像预处理方法，目的是让图像的亮暗变化范围更加稳定，减少光照差异对模型学习的影响。对比度 = 图像中亮和暗的差异程度。

局部平均池化是 CNN 中一种下采样操作，作用是把一个局部区域内的像素或特征值取平均，用一个值代表这个区域。



为了达到目的可以在现有的激活函数上各种改，加绝对值啥的

2.2 LRN

Local Response Normalization，局部响应归一化（亮度归一化）

文中用于提高模型泛化能力

对第 i 个卷积核在某个像素（位置）进行卷积，再经 ReLU 激活的值，即该位置的响应，除以附近卷积核的响应，（根据附近卷积核的响应强度进行归一化抑制），得到新响应。

分子是当前卷积核的响应，分母反映当前位置附近多个卷积核的总响应强度。如果附近卷积核整体响应很强，分母变大，当前响应会被更强地抑制；如果附近响应较弱，分母较小，当前较大的响应会被较好地保留下来（即，分子固定，如果分母大，则归一，如果分母小，说明就是重要特征，保留分子数值大的特征）

保留了重要特征，所以更准了

2.3 CNN





3. 什么是先验知识？

也就是在网络结构设计时，人为加入的一些关于“应该关注什么、应该怎样学习”的假设

ImageNet 虽然有百万级图片，但仍无法覆盖真实世界所有视觉情况。因此模型不能只依赖数据，还需要利用 CNN 结构中包含的视觉先验（例如局部连接、权重共享、层次特征提取），通过改变网络的深度和宽度，可以控制它们的学习能力；以及对图片有强大正确假设，从而用有限的数据学习复杂的物体识别任务。

2.3.1 整体架构






2.3.2 重叠池化

步长 s 与池化窗口大小 z 进行比较:

若 $s < z$, 则必然会重叠, 泛指不重叠


重叠池化的优点: 能更好保留空间特征信息, 如果不重叠, 一个特征可能恰好分到两个区域; 减少过拟合, 池化本身降低空间分辨率。重叠池化让输出变化更平滑(平滑过渡, 无法死记硬背位置), 模型不容易死记训练样本



3. GPU

- 加快训练速度

两个GPU的设计，一个数据分两份



4. 减少过拟合

防止模型背会训练数据


类别	方法	核心思想	适用场景
数据层面	收集更多数据	增加真实样本数量	数据不足、复杂任务
	数据增强（Data Augmentation）	人工生成更多训练样本	图像、语音、文本任务
	加噪声（Noise Injection）	增加输入或参数随机性	数据存在噪声、 希望提高泛化能力
模型结构层面	减少层数	降低网络深度	模型过大、小数据集
	减少神经元数量	降低参数量	全连接层过大时
	参数共享（Parameter Sharing）	多任务共享参数	CNN卷积、Transformer等
训练策略层面	Early Stopping（早停）	在验证集性能下降前停止训练	训练时间较长、 出现过拟合趋势
	学习率调整（Learning Rate Scheduling）	动态改变学习率	深度神经网络训练
正则化层面	L1正则化	限制权重绝对值	特征较多、希望稀疏模型
	L2正则化（Weight Decay）	限制权重大小	几乎所有深度学习任务
	Dropout	随机关闭部分神经元	大型全连接网络、CNN
	Label Smoothing（标签平滑）	降低标签置信度	分类任务
	Batch Normalization	标准化中间特征分布	深度神经网络
知识利用层面	迁移学习（Transfer Learning）	利用已有模型知识	小数据集任务
	预训练模型（Pre-trained Model）	提前学习通用特征	CV、NLP、大模型
	Fine-tuning（微调）	在新任务上继续训练	下游任务适配

4.1 数据增强

让模型看到更多不同情况的数据

水平翻转；旋转；裁剪；调整亮度；加噪声（如PCA颜色扰动等）

- 生成图像平移和水平翻转



- PCA（主成分分析）颜色扰动

$$[R, G, B]' = [R, G, B] + \text{颜色主方向} \times \text{随机幅度}$$

AlexNet 对 ImageNet 全部 RGB 像素做 PCA，找到颜色变化的主要方向，然后沿这些方向随机改变整张图片的颜色，使模型学习到对光照和颜色变化不敏感的特征，从而提高泛化能力

4.2 降低模型复杂度

减少层数;减少神经元数量（易发生欠拟合）

4.3 L2正则化（Weight Decay）

加入 $\lambda \sum w^2$ (L2正则项), λ 过大，参数会过小，发生欠拟合

L2鼓励：使用更小、更平滑的参数

4.4 Dropout

前向，反向传播过程中，每个神经元有百分之五十的概率丢失（例如：p=0.5）

使得网络结构不固定，但共享一套权重

迫使每个神经元学习独立、有用的特征。

训练速度会变慢，需要调整drop概率（例如：p=0.5）

4.5 Early Stopping(早停)

需要验证集，改变的是epochs

通过观察验证loss和训练loss，如果训练loss下降但验证loss上升则停止训练

4.6 批量归一化（BN，Batch Normalization）

对一个 mini-batch 中某一层神经元的输出进行标准化，使其均值接近 0，方差接近 1，然后再通过可学习参数恢复表达能力。

公式：
$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

- μ_B 当前batch的均值; σ_B^2 当前batch的方差; ϵ 防止除零的小常数

然后进行缩放和平移: $y = \gamma \hat{x} + \beta$

- γ 可学习缩放参数; β : 可学习偏移参数

方法	英文	中文
Batch Normalization	BN	批量归一化
Layer Normalization	LN	层归一化
Instance Normalization	IN	实例归一化
Group Normalization	GN	组归一化

4.7 Label Smoothing（标签平滑）

使用在大规模数据集上已经学习好的模型参数，再迁移到自己的任务