

使用深度卷积神经网络进行ImageNet数据集分类

摘要

我们训练了一个大型的深度卷积神经网络，用于将 ImageNet LSVRC-2010 竞赛中的 120 万张高分辨率图像分类到 1000 个不同的类别中。在测试数据上，我们取得了 37.5% 的 Top-1 错误率和 17.0% 的 Top-5 错误率，这一结果明显优于此前最先进的方法。该神经网络拥有 6000 万个参数和 65 万个神经元，由五个卷积层组成，其中一些卷积层之后连接了最大池化层，并包含三个全连接层，最后通过一个 1000 类的 Softmax 层进行分类。为了加快训练速度，我们使用了非饱和神经元以及一种非常高效的卷积操作 GPU 实现方法。为了减少全连接层中的过拟合问题，我们采用了一种最近提出的、称为“dropout”的正则化方法，该方法被证明非常有效。我们还将该模型的一个变体提交到了 ILSVRC-2012 竞赛中，并取得了 15.3% 的 Top-5 测试错误率，而第二名参赛方法取得的 Top-5 测试错误率为 26.2%。

1. 引言

当前的物体识别方法主要依赖于机器学习方法。为了提高它们的性能，我们可以收集更大的数据集，学习更强大的模型，并采用更好的防止过拟合的技术。直到最近，带标签图像数据集的规模仍然相对较小——通常只有数万张图像（例如 NORB [16]、Caltech-101/256 [8, 9] 和 CIFAR-10/100 [12]）。对于这种规模的数据集，简单的识别任务已经能够取得较好的效果，尤其是在使用保持标签不变的变换方法进行数据增强之后。例如，目前在 MNIST 手写数字识别任务上的最佳错误率（低于 0.3%）已经接近人类水平 [4]。但是，现实环境中的物体具有很大的变化性，因此为了学习识别这些物体，必须使用规模更大的训练集。事实上，小规模图像数据集的不足之处已经被广泛认识到（例如 Pinto 等人 [21]），但直到最近，人们才有能力收集包含数百万张图像的带标签数据集。新的大规模数据集包括 LabelMe [23]，它由数十万张经过完整分割标注的图像组成；以及 ImageNet [6]，它包含超过 1500 万张带标签的高分辨率图像，覆盖超过 22000 个类别。

要从数百万张图像中学习数千种物体，我们需要一个具有强大学习能力的模型。然而，物体识别任务具有极高的复杂性，这意味着即使像 ImageNet 这样规模的数据集也无法完全描述这一问题。因此，我们的模型还应该具有大量的先验知识，以弥补我们所缺少的所有数据。卷积神经网络（CNN）正是这样一类模型 [16, 11, 13, 18, 15, 22, 26]。通过改变网络的深度和宽度，可以控制它们的学习能力；同时，它们也对图像的性质做出了强大且大部分正确的假设（即图像统计特征的平稳性以及像素依赖关系的局部性）。因此，与具有相似规模层的标准前馈神经网络相比，CNN 具有更少的连接和参数，因此更容易训练，而它们理论上的最佳性能可能只会略微逊色。

尽管 CNN 具有许多吸引人的特性，并且其局部连接结构在计算效率方面具有相对优势，但将它们大规模应用于高分辨率图像仍然需要付出高昂的计算成本。幸运的是，当前的 GPU 配合高度优化的二维卷

积实现，已经足以支持训练规模较大的 CNN 模型；同时，近年来出现的数据集（例如 ImageNet）包含了足够数量的标注样本，使得训练这类模型时不会出现严重的过拟合问题。

本文的具体贡献如下：我们在 ILSVRC-2010 和 ILSVRC-2012 竞赛所使用的 ImageNet 子集上训练了截至当时规模最大的卷积神经网络之一，并在这些数据集上取得了迄今为止报道过的最佳结果。我们编写了一套高度优化的 GPU 实现程序，用于执行二维卷积以及训练卷积神经网络过程中涉及的其他所有操作，并将其公开提供。我们的网络包含一些新的且不同寻常的特征，这些特征提升了模型性能并减少了训练时间，具体内容将在第 3 节中详细介绍。即使拥有 120 万个带标签的训练样本，我们网络的规模仍然使过拟合成为一个严重问题，因此我们采用了多种有效的防止过拟合技术，这些方法将在第 4 节中介绍。最终的网络包含五个卷积层和三个全连接层，而这种深度似乎十分重要：我们发现，移除任意一个卷积层（每个卷积层所包含的参数都不超过整个模型参数的 1%）都会导致性能下降。

最终，网络的规模主要受到两个因素的限制：当前 GPU 可用的内存容量，以及我们能够接受的训练时间长度。我们的网络在两块 GTX 580 3GB GPU 上训练需要五到六天时间。我们所有的实验都表明，只要等待更快的 GPU 和更大规模的数据集出现，我们的结果就可以通过简单地增加计算资源和数据规模得到进一步提升。

2. 数据集

ImageNet 是一个包含超过 1500 万张带标签高分辨率图像的数据集，这些图像属于大约 22000 个类别。这些图像从互联网上收集，并由人工标注者使用亚马逊的 Mechanical Turk 众包工具进行标签标注。自 2010 年起，作为 Pascal Visual Object Challenge 的一部分，每年都会举办一项名为 ImageNet 大规模视觉识别挑战赛（ImageNet Large-Scale Visual Recognition Challenge, ILSVRC）的竞赛。ILSVRC 使用 ImageNet 的一个子集，其中包含 1000 个类别，每个类别大约有 1000 张图像。总计，该数据集包含大约 120 万张训练图像、5 万张验证图像以及 15 万张测试图像。

ILSVRC-2010 是 ILSVRC 中唯一一个提供测试集标签的版本，因此我们的大部分实验都是在该版本上进行的。由于我们也将模型提交到了 ILSVRC-2012 竞赛中，因此在第 6 节中我们也报告了模型在该版本数据集上的结果，而该版本的测试集标签是不可获得的。在 ImageNet 上，通常会报告两种错误率：Top-1 错误率和 Top-5 错误率。其中，Top-5 错误率指的是：在测试图像中，模型认为概率最高的五个类别中不包含正确标签的图像所占的比例。

ImageNet 包含不同分辨率的图像，而我们的系统要求输入具有固定的维度。因此，我们将图像下采样到固定的 256×256 分辨率。对于一张矩形图像，我们首先对其进行缩放，使较短的一边长度变为 256，然后从缩放后的图像中裁剪出中心位置的 256×256 区域。除此之外，我们没有对图像进行任何其他预处理，唯一的处理方式是从每个像素中减去训练集上的平均活动值（即均值）。因此，我们的网络是在经过中心化处理后的原始 RGB 像素值上进行训练的。

3. 架构

我们网络的结构总结如图 2 所示。该网络包含八个需要学习参数的层——五个卷积层和三个全连接层。下面，我们将介绍网络结构中一些新的或不同寻常的特征。第 3.1 至第 3.4 节按照我们对这些特征重要性的估计进行排序，其中最重要的特征排在最前面。

3.1 ReLU 非线性

通常用于表示神经元输出 f 与其输入 x 之间关系的方法，是使用

$f(x) = \tanh(x)$ 或 $f(x) = (1 + e^{-x})^{-1}$ 。从梯度下降训练时间的角度来看，这些饱和型非线性函数的训练速度远慢于非饱和非线性函数 $f(x) = \max(0, x)$ 。遵循 Nair 和 Hinton [20] 的工作，我们将使用这种非线性的神经元称为修正线性单元（Rectified Linear Units, ReLUs）。使用 ReLU 的深度卷积神经网络相比于使用 $\tanh$ 单元的等价网络，训练速度快了数倍。图 1 展示了这一点，该图显示了在一个特定的四层卷积网络中，在 CIFAR-10 数据集上达到 25% 训练误差所需的迭代次数。该结果表明，如果我们采用传统的饱和型神经元模型，就无法在本文中对如此大型的神经网络进行实验。

我们并不是第一个在 CNN 中考虑替代传统神经元模型的方法。例如，Jarrett 等人 [11] 认为，在 Caltech-101 数据集上，他们所采用的对比度归一化（contrast normalization）之后接局部平均池化（local average pooling）的模型中，非线性函数 $f(x) = |\tanh(x)|$ 表现得特别好。然而，在这个数据集中，主要关注的问题是防止过拟合，因此他们观察到的效果不同于我们在使用 ReLU 时所报告的加速拟合训练集的能力。更快的学习速度对于在大规模数据集上训练的大型模型的性能具有重要影响。




图 1：一个使用 ReLU 激活函数的四层卷积神经网络（实线）在 CIFAR-10 数据集上达到 25% 的训练错误率，其速度比使用 tanh 神经元的等价网络（虚线）快六倍。两个网络的学习率分别独立选择，以使

训练速度达到最快。实验中没有使用任何形式的正则化方法。这里展示的效果强弱会随着网络结构的不同而变化，但使用 ReLU 的网络始终比使用饱和型神经元（saturating neurons）的等价网络学习速度快数倍。

3.2 多 GPU 训练

单个 GTX 580 GPU 只有 3GB 的显存，这限制了能够在其上训练的网络的最大规模。事实证明，120 万个训练样本足以训练出一些大到无法放入单个 GPU 的网络。因此，我们将网络分布到两个 GPU 上进行训练。当前的 GPU 特别适合进行跨 GPU 并行计算，因为它们能够直接读写彼此的内存，而不需要经过主机内存。我们采用的并行化方案本质上是有一半的卷积核（或神经元）放置在每个 GPU 上，并加入了一个额外的技巧：两个 GPU 只在特定的层之间进行通信。这意味着，例如，第 3 层的卷积核会接收第 2 层所有卷积核映射（kernel maps）的输入。然而，第 4 层的卷积核只接收位于同一个 GPU 上的第 3 层卷积核映射的输入。选择连接模式是一个需要通过交叉验证解决的问题，但这种方式使我们能够精确调整通信量，直到它占计算量的比例达到可接受的程度。

最终得到的网络结构与 Cireřan 等人 [5] 使用的“柱状”（columnar）CNN 有些相似，但我们的网络中的这些列并不是相互独立的（见图 2）。与在单个 GPU 上训练、且每个卷积层中卷积核数量减半的网络相比，这种方案分别将我们的 Top-1 和 Top-5 错误率降低了 1.7% 和 1.2%。双 GPU 网络的训练时间甚至略少于单 GPU 网络。

3.3 局部响应归一化

ReLU 具有一个理想的特性，即它不需要输入归一化（input normalization）来防止自身发生饱和。如果至少有一些训练样本能够为某个 ReLU 神经元产生正输入，那么该神经元就会进行学习。然而，我们仍然发现，下面介绍的局部归一化方法有助于提高模型的泛化能力。记 $a_{x,y}^i$ 表示这样得到的某个神经元的激活值：首先在位置 (x, y) 处使用第 i 个卷积核进行计算，然后再经过 ReLU 非线性激活函数。经过响应归一化（response normalization）后的激活值 $b_{x,y}^i$ 可以由如下公式表示：

$$b_{x,y}^i = \frac{a_{x,y}^i}{\left(k + \alpha \sum_{j=\max(0, i-n/2)}^{\min(N-1, i+n/2)} (a_{x,y}^j)^2\right)^\beta}$$

其中，求和范围覆盖了在相同空间位置上的 n 个“相邻”卷积核映射（kernel maps），而 N 表示该层中卷积核的总数量。卷积核映射的排列顺序当然是任意的，并且在训练开始之前就已经确定。这种响应归一化方法实现了一种受真实神经元中侧向抑制（lateral inhibition）机制启发的形式，使得由不同卷积核计算得到的神经元输出之间产生竞争，从而抑制较大的激活值。常数 k 、 n 、 α 和 β 是超参数（hyper-parameters），它们的取值通过验证集确定；我们使用的参数值为 $k = 2$ 、 $n = 5$ 、 $\alpha = 10^{-4}$ 和 $\beta = 0.75$ 。我们在某些层中应用了这种归一化操作，并且是在 ReLU 非线性激活之后进行归一化的（见第 3.5 节）。

这种方法与 Jarrett 等人 [11] 提出的局部对比度归一化（local contrast normalization）方法有一些相似之处，但更准确地说，我们的方法应该称为“亮度归一化”（brightness normalization），因为我们并没有减去平均激活值。响应归一化分别使我们的 Top-1 和 Top-5 错误率降低了 1.4% 和 1.2%。我们还在 CIFAR-10 数据集上验证了这种方法的有效性：一个四层 CNN 在不进行归一化时取得了 13% 的测试错误率，而使用归一化后测试错误率降低到了 11%。

3.4 重叠池化（Overlapping Pooling）

CNN 中的池化层用于对同一个卷积核映射（kernel map）中相邻神经元组的输出进行汇总。传统上，相邻池化单元所汇总的区域之间并不重叠（例如 [17, 11, 4]）。更准确地说，一个池化层可以被看作由一个池化单元网格组成，这些池化单元之间相隔 s 个像素，并且每个池化单元都会汇总一个以该池化单元位置为中心、大小为 $z \times z$ 的邻域区域。如果设置 $s=z$ ，则得到 CNN 中常用的传统局部池化。如果设置 $s < z$ ，则得到重叠池化。我们的整个网络都采用这种方式，其中 $s=2$ ， $z=3$ 。与非重叠池化方案 $s=2, z=2$ 相比（两者产生相同维度的输出），这种方法分别将 Top-1 和 Top-5 错误率降低了 0.4% 和 0.3%。我们通常在训练过程中观察到，采用重叠池化的模型稍微更难出现过拟合。

3.5 整体架构（Overall Architecture）

现在我们可以描述 CNN 的整体结构了。如图 2 所示，该网络包含八个带有权重的层；其中前五层是卷积层，后三层是全连接层。最后一个全连接层的输出被输入到一个 1000 类的 Softmax 层中，该层会生成一个关于 1000 个类别标签的概率分布。我们的网络最大化多项逻辑回归（multinomial logistic regression）目标函数，这等价于最大化在预测分布下，所有训练样本中正确标签对应概率的平均值。

第二、第四和第五个卷积层中的卷积核，仅与上一层中位于同一个 GPU 上的那些卷积核映射相连接（见图 2）。第三个卷积层中的卷积核则与第二层中的所有卷积核映射相连接。全连接层中的神经元与上一层中的所有神经元相连接。响应归一化层（response-normalization layers）位于第一个和第二个卷积层之后。第 3.4 节所描述类型的最大池化层（max-pooling layers）位于两个响应归一化层之后以及第五个卷积层之后。ReLU 非线性激活函数被应用于每一个卷积层和全连接层的输出。

第一个卷积层使用 96 个大小为 $11 \times 11 \times 3$ 的卷积核，对输入的 $224 \times 224 \times 3$ 图像进行卷积，步长（stride）为 4 个像素（即同一个卷积核映射中相邻神经元感受野中心之间的距离）。第二个卷积层接收第一个卷积层经过响应归一化和池化后的输出作为输入，并使用 256 个大小为 $5 \times 5 \times 48$ 的卷积核进行卷积。第三、第四和第五个卷积层之间直接相连，中间没有任何池化层或归一化层。第三个卷积层包含 384 个大小为 $3 \times 3 \times 256$ 的卷积核，并连接到第二个卷积层经过归一化和池化后的输出。第四个卷积层包含 384 个大小为 $3 \times 3 \times 192$ 的卷积核，第五个卷积层包含 256 个大小为 $3 \times 3 \times 192$ 的卷积核。三个全连接层每层都包含 4096 个神经元。




图 2：展示了我们 CNN 的结构示意图，并明确展示了两块 GPU 之间的任务划分。一个 GPU 运行图中上半部分的网络层，而另一个 GPU 运行图中下半部分的网络层。两个 GPU 仅在某些特定层之间进行通信。该网络的输入维度为 150,528，网络后续各层中的神经元数量依次为 253,440—186,624—64,896—64,896—43,264—4096—4096—1000 253,440-186,624-64,896-64,896-43,264-4096-4096-1000

4. 减少过拟合

我们的神经网络结构包含 6000 万个参数。尽管 ILSVRC 的 1000 个类别使得每个训练样本能够对从图像到标签的映射施加 10 bit 的约束，但事实证明，仅凭这些约束不足以在不过度拟合的情况下学习如此多的参数。下面，我们将介绍两种主要用于减少过拟合的方法。

4.1 数据增强

减少图像数据过拟合最简单且最常用的方法，是利用保持标签不变的变换方法（例如 [25, 4, 5]）对数据集进行人工扩充。我们采用了两种不同形式的数据增强方法，这两种方法都能够以极低的计算成本从原始图像生成变换后的图像，因此不需要将变换后的图像存储在磁盘中。在我们的实现中，当 GPU 正在训练上一批图像时，变换后的图像由 CPU 上运行的 Python 代码实时生成。因此，从实际效果来看，这些数据增强方法几乎不产生额外的计算开销。

第一种数据增强方法包括生成图像平移和水平翻转。我们通过从 256×256 的图像中随机提取 224×224 的图像块（以及它们的水平翻转版本），并使用这些提取出的图像块训练网络。这样使训练集规模扩大了 2048 倍，不过显然，生成的训练样本之间存在高度的相关性。如果没有这种方法，我们的网络会出现严重的过拟合问题，这将迫使我们使用规模小得多的网络。在测试阶段，网络通过提取五个 224×224 的图像块（四个角落的图像块和一个中心图像块），以及它们的水平翻转版本（因此总共得到十个图像块）进行预测，然后对网络 Softmax 层在这十个图像块上的预测结果取平均。

第二种数据增强方法包括改变训练图像中 RGB 通道的强度。具体来说，我们在整个 ImageNet 训练集的 RGB 像素值集合上执行 PCA（主成分分析）。对于每一张训练图像，我们添加若干个所得到的主成分，其幅度与对应的特征值以及从均值为 0、标准差为 0.1 的高斯分布中随机采样得到的随机变量成比例。因此，对于每个 RGB 图像像素 $I_{xy} = [I_{xy}^R, I_{xy}^G, I_{xy}^B]^T$ ，我们添加如下量：

$$[p_1, p_2, p_3][\alpha_1 \lambda_1, \alpha_2 \lambda_2, \alpha_3 \lambda_3]^T$$

其中， p_i 和 λ_i 分别表示 RGB 像素值 3×3 协方差矩阵的第 i 个特征向量和特征值，而 α_i 是前面提到的随机变量。对于一张特定的训练图像，所有像素共享同一组 α_i ，直到该图像再次被用于训练时，才重新进行采样。这种方法近似地捕捉了自然图像中的一个重要性质，即物体的类别身份对于光照强度和颜色变化具有不变性。这种方法使 Top-1 错误率降低了超过 1%。

4.2 Dropout

结合多个不同模型的预测结果是一种非常有效的降低测试误差的方法 [1, 3]，但对于已经需要数天时间训练的大型神经网络来说，这种方法的代价似乎过于昂贵。然而，有一种非常高效的模型组合方法，在训练过程中只增加大约两倍的计算成本。最近提出的一种称为“dropout” [10] 的技术，其方法是以 0.5 的概率将每个隐藏神经元的输出设置为 0。以这种方式“丢弃”的神经元不会参与前向传播，也

不会参与反向传播。因此，每次输入一个样本时，神经网络都会随机采样出一种不同的网络结构，但所有这些网络结构共享相同的权重。这种技术减少了神经元之间复杂的协同适应（co-adaptation），因为某个神经元不能依赖于其他特定神经元的存在。因此，它被迫学习更加鲁棒的特征，这些特征能够与其他神经元的许多不同随机子集结合使用。

在测试阶段，我们使用所有神经元，但将它们的输出乘以 0.5。这是一种合理的近似方法，可以近似于对数量呈指数增长的 dropout 网络所产生的预测分布取几何平均。在图 2 所示的网络中，我们在前两个全连接层中使用了 dropout。如果不使用 dropout，我们的网络会出现严重的过拟合问题。Dropout 大约使模型收敛所需的迭代次数增加了一倍。

5. 学习细节

我们使用随机梯度下降（stochastic gradient descent, SGD）训练模型，批量大小（batch size）设置为 128 个样本，动量（momentum）设置为 0.9，权重衰减（weight decay）设置为 0.0005。我们发现，这种较小程度的权重衰减对于模型学习非常重要。换句话说，在这里权重衰减不仅仅是一种正则化方法，它还能够降低模型的训练误差。权重 w 的更新规则如下：

$$v_{i+1} := 0.9 \cdot v_i - 0.0005 \cdot \epsilon \cdot w_i - \epsilon \cdot \left\langle \frac{\partial L}{\partial w} \Big|_{w_i} \right\rangle_{D_i}$$
$$w_{i+1} := w_i + v_{i+1}$$

其中， i 是迭代索引（iteration index）， v 是动量变量（momentum variable）， ϵ 是学习率

（learning rate），而 $\left\langle \frac{\partial L}{\partial w} \Big|_{w_i} \right\rangle_{D_i}$ 表示在第 i 个批次 D_i 上，对目标函数关于权重 w 的导数的平均值，并且该导数是在 w_i 处计算得到的。

我们将每一层的权重初始化为均值为 0、标准差为 0.01 的高斯分布。我们将第二、第四和第五个卷积层，以及全连接隐藏层中的神经元偏置初始化为常数 1。这种初始化方式通过为 ReLU 提供正输入，加速了学习的早期阶段。我们将其余层中的神经元偏置初始化为常数 0。

我们对所有层使用相同的学习率，并在训练过程中手动对其进行调整。我们采用的启发式策略是：当验证集错误率在当前学习率下不再继续降低时，将学习率缩小为原来的十分之一。初始学习率设置为 0.01，并在训练结束前降低了三次。我们在包含 120 万张图像的训练集上训练网络，大约进行了 90 轮迭代（cycles），整个训练过程在两块 NVIDIA GTX 580 3GB GPU 上耗时五到六天。




图 3：第一个卷积层在 $224 \times 224 \times 3$ 的输入图像上学习得到的 96 个大小为 $11 \times 11 \times 3$ 的卷积核。其中，上方的 48 个卷积核由 GPU 1 学习得到，下方的 48 个卷积核由 GPU 2 学习得到。具体细节见第 6.1 节。

6. 结果 (Results)

我们在 ILSVRC-2010 上的结果总结于表 1 中。我们的网络在测试集上取得了 37.5% 的 Top-1 错误率和 17.0% 的 Top-5 错误率。ILSVRC 2010 竞赛中取得的最佳结果为 47.1% 的 Top-1 错误率和 28.2% 的 Top-5 错误率，该方法通过对六个基于不同特征训练的稀疏编码模型 (sparse-coding models) 的预测结果进行平均得到。此后，已发表的最佳结果为 45.7% 的 Top-1 错误率和 25.7% 的 Top-5 错误率，该方法通过对两个分类器的预测结果进行平均得到，这两个分类器分别基于两种密集采样特征 (densely-sampled features) 计算得到的 Fisher Vector (FV) 进行训练。

表 1：ILSVRC 2010 测试集上的结果对比。斜体表示其他方法取得的最佳结果。

Model	Top-1	Top-5
<i>Sparse coding [2]</i>	<i>47.1%</i>	<i>28.2%</i>
<i>SIFT + FVs [24]</i>	<i>45.7%</i>	<i>25.7%</i>
CNN	37.5%	17.0%

我们也将模型提交到了 ILSVRC-2012 竞赛中，并在表 2 中报告了结果。由于 ILSVRC-2012 测试集的标签并未公开，因此我们无法报告所有尝试过模型的测试错误率。在本段剩余部分中，我们将验证集错误率和测试集错误率视为可以互换的指标，因为根据我们的经验，两者之间的差异不会超过 0.1%（见表 2）。本文所描述的 CNN 取得了 18.2% 的 Top-5 错误率。对五个相似 CNN 的预测结果进行平均后，错误率降低到了 16.4%。我们还训练了一个 CNN，在最后一个池化层之后额外增加了第六个卷积层，用于对整个 ImageNet Fall 2011 数据集（1500 万张图像，22000 个类别）进行分类，然后再在

ILSVRC-2012 数据集上进行“微调”（fine-tuning），最终取得了 16.6% 的错误率。将两个在整个 Fall 2011 数据集上进行预训练的 CNN 与前面提到的五个 CNN 的预测结果进行平均后，错误率进一步降低到了 15.3%。竞赛中的第二名方法取得了 26.2% 的错误率，该方法通过对多个分类器的预测结果进行平均得到，这些分类器基于不同类型的密集采样特征（densely-sampled features）计算得到的 Fisher Vector（FV）进行训练。

表 2：ILSVRC-2012 验证集和测试集上的错误率对比。斜体表示其他方法取得的最佳结果。带有星号（*）的模型经过“预训练”（pre-trained），即先用于对整个 ImageNet 2011 Fall 版本数据集进行分类训练。具体细节见第 6 节。

Model	Top-1 (val)	Top-5 (val)	Top-5 (test)
<i>SIFT + FVs [7]</i>	—	—	26.2%
1 CNN	40.7%	18.2%	—
5 CNNs	38.1%	16.4%	16.4%
1 CNN*	39.0%	16.6%	—
7 CNNs*	36.7%	15.4%	15.3%

最后，我们还报告了模型在 ImageNet Fall 2009 版本数据集上的错误率，该数据集包含 10184 个类别和 890 万张图像。在这个数据集上，我们遵循文献中的惯例，将一半图像用于训练，另一半图像用于测试。由于该数据集没有已经确定的测试集，因此我们的数据划分必然不同于之前研究者所采用的划分方式，但这并不会明显影响实验结果。在该数据集上，我们的 Top-1 和 Top-5 错误率分别为 67.4% 和 40.9%。该结果由上述网络获得，但在最后一个池化层之后额外增加了第六个卷积层。此前在该数据集上发表的最佳结果为 78.1% 的 Top-1 错误率和 60.9% 的 Top-5 错误率 [19]。

6.1 定性评估（Qualitative Evaluations）

图 3 展示了网络两个数据连接层（data-connected layers）学习到的卷积核。该网络学习到了各种对频率和方向具有选择性的卷积核，以及各种不同颜色的块状特征。注意两个 GPU 所表现出的专门化特性，这是第 3.5 节中所描述的受限连接方式带来的结果。GPU 1 上的卷积核大多对颜色不敏感，而 GPU 2 上的卷积核大多对颜色具有特异性。这种专门化现象在每一次训练中都会出现，并且与特定的随机权重初始化方式无关（除了 GPU 编号重新排列的情况）。




图 4：（左）八张 ILSVRC-2010 测试图像，以及我们的模型认为概率最高的五个标签。每张图像下方标出了正确标签，并且如果正确标签恰好出现在 Top-5 预测结果中，还用红色条形显示模型分配给该正确标签的概率。（右）第一列展示了五张 ILSVRC-2010 测试图像。其余列展示了六张训练图像，这些图像在最后一个隐藏层中产生的特征向量与测试图像对应特征向量之间具有最小的欧氏距离。

在图 4 的左侧面板中，我们通过计算网络对八张测试图像的 Top-5 预测结果，对网络所学习到的知识进行了定性评估。注意，即使是不位于图像中心的物体，例如左上角的螨虫（mite），网络也能够进行识别。大多数 Top-5 标签看起来都是合理的。例如，对于豹子图像，只有其他类型的猫科动物会被认为是可能的标签。在某些情况下（例如格栅 grille、樱桃 cherry），照片想要表达的主要对象确实存在一定的歧义。

探究网络视觉知识的另一种方法，是考察一张图像在最后一个 4096 维隐藏层中产生的特征激活。如果两张图像产生的特征激活向量之间具有较小的欧氏距离（Euclidean distance），那么我们可以认为神经网络的高层特征表示认为这两张图像是相似的。图 4 展示了五张测试集图像，以及根据这一度量标准，与每张测试图像最相似的六张训练集图像。注意，在像素层面上，检索得到的训练图像通常并不会与第一列中的查询图像具有较小的 L2 距离。例如，检索出的狗和大象图像呈现出了各种不同的姿态。我们在补充材料中展示了更多测试图像的实验结果。

使用两个 4096 维实值向量之间的欧氏距离来计算相似度效率较低，但可以通过训练一个自编码器（auto-encoder），将这些向量压缩成较短的二进制编码，从而提高计算效率。相比直接将自编码器应用于原始像素的方法 [14]，这种方式应该能够产生效果更好的图像检索方法，因为原始像素方法没有利用图像标签信息，因此往往会检索出具有相似边缘模式的图像，而这些图像未必具有语义上的相似性。

7. 讨论

我们的结果表明，一个大型的深度卷积神经网络能够仅通过纯监督学习（purely supervised learning），在一个极具挑战性的数据集上取得突破性的成果。值得注意的是，如果移除任意一个卷积层，网络的性能都会下降。例如，移除中间的任意一层都会导致网络 Top-1 性能下降约 2%。因此，网络的深度对于取得我们的实验结果确实非常重要。

为了简化实验过程，我们没有使用任何无监督预训练（unsupervised pre-training），尽管我们认为它可能会带来帮助，尤其是在我们获得足够计算能力以显著增大网络规模，同时不会相应增加标注数据量的情况下。到目前为止，随着我们不断增大网络规模并延长训练时间，实验结果一直在提升；但为了达到人类视觉系统中腹侧视觉通路（infero-temporal pathway）的水平，我们仍然需要跨越多个数量级的差距。最终，我们希望能够在视频序列上使用非常大规模且深层的卷积神经网络，因为视频中的时间结构能够提供非常有价值的信息，而这些信息在静态图像中是缺失的，或者远不如视频中明显。