

ResNet翻译

摘要

更深的神经网络更加难以训练。我们提出了一种残差学习框架，用于缓解训练比以往网络深得多的网络时遇到的困难。我们明确地将网络层重新表示为相对于层输入进行学习的残差函数，而不是学习没有参考输入的函数。我们提供了全面的实验验证，表明这些残差网络更容易优化，并且可以通过显著增加网络深度来提升准确率。在 ImageNet 数据集上，我们评估了深度最多达到 152 层的残差网络——其深度是 VGG 网络 [41] 的 8 倍，但仍具有更低的复杂度。由这些残差网络组成的集成模型在 ImageNet 测试集上取得了 3.57% 的错误率，该结果赢得了 ILSVRC 2015 分类任务的第一名。我们还在 CIFAR-10 数据集上对具有 100 层和 1000 层深度的网络进行了分析。





表示的深度对于许多视觉识别任务来说具有核心的重要性。仅仅得益于我们极深的网络表示，我们就在 COCO 目标检测数据集上取得了 28% 的相对提升。深度残差网络是我们参加 ILSVRC 和 COCO 2015 竞赛所提交方法的基础¹，在这些竞赛中，我们还分别在 ImageNet 检测、ImageNet 定位、COCO 检测以及 COCO 分割任务中获得了第一名。

1. 引言

深度卷积神经网络 [22, 21] 已经在图像分类任务 [21, 50, 40] 中取得了一系列突破。深度网络能够以端到端的多层方式自然地整合低层、中层和高层特征 [50] 以及分类器，而特征的“层次”可以通过堆叠层数（深度）的增加得到丰富。近期的研究结果 [41, 44] 表明，网络深度具有至关重要的作用。在具有挑战性的 ImageNet 数据集 [36] 上取得领先结果的方法 [41, 44, 13, 16] 都采用了“非常深”的模型 [41]，网络深度从 16 层 [41] 到 30 层 [16] 不等。许多其他复杂的视觉识别任务 [8, 12, 7, 32, 27] 也同样从非常深的模型中获得了显著收益。

受网络深度重要性的推动，一个问题随之产生：学习更好的网络是否就像简单地堆叠更多层一样容易？阻碍回答这一问题的一个障碍是臭名昭著的梯度消失/梯度爆炸问题 [1, 9]，它会从训练开始阶段就阻碍网络的收敛。然而，通过归一化初始化方法 [23, 9, 37, 13] 和中间归一化层 [16]，这一问题已经得到了很大程度的解决。这些方法使得具有数十层深度的网络能够通过随机梯度下降（SGD）结合反向传播 [22] 开始进行收敛。

当更深的网络能够开始收敛时，一个退化问题逐渐显现出来：随着网络深度的增加，准确率会达到饱和（这可能并不令人意外），随后会快速下降。出乎意料的是，这种退化并不是由过拟合导致的，并且正如 [11, 42] 中所报道的，以及我们的实验充分验证的那样，在一个已经足够深的模型中增加更多层会导致更高的训练误差。图 1 展示了一个典型示例。







图 1. 在 CIFAR-10 数据集上, 20 层和 56 层“普通” (plain) 网络的训练误差 (左) 和测试误差 (右)。更深的网络具有更高的训练误差, 因此也具有更高的测试误差。在 ImageNet 上也观察到了类似现象, 具体见图 4。

(训练准确率的) 退化现象表明, 并不是所有系统都同样容易进行优化。考虑一个较浅的网络结构, 以及在其基础上增加更多层得到的更深网络。对于这个更深的模型, 通过构造可以得到一个解决方案: 新增的层采用恒等映射, 而其他层则复制较浅模型中已经学习到的参数。这个构造出的解决方案的存在说明, 更深的模型的训练误差应该不会高于较浅模型。然而实验表明, 我们目前所使用的优化方法无法找到与该构造方案同样好甚至更优的解 (或者无法在可接受的时间内找到这样的解)。

在本文中, 我们通过引入一种深度残差学习框架来解决退化问题。不同于期望每几个堆叠层直接拟合所需的底层映射, 我们明确地让这些层去拟合一个残差映射。形式上, 假设所需的底层映射表示为 $H(x)$, 我们让堆叠的非线性层去拟合另一个映射 $F(x) := H(x) - x$ 。原始映射可以重新表示为 $F(x) + x$ 。我们假设, 优化残差映射比优化原始的、无参考输入的映射更加容易。极端情况下, 如果一个恒等映射是最优解, 那么让残差趋近于零会比通过一组非线性层去拟合一个恒等映射更加容易。



Handwritten notes explaining the residual learning process:

$x \rightarrow y$
 $\downarrow$
 $H(x)$
 $\downarrow$
 0

减小 $H(x)$ 与 x 的残差 $F(x)$
 达到 $x \rightarrow y = H(x)$ 的目的




图 2. 残差学习：一个构建模块 (building block)。

$F(x) + x$ 这种形式可以通过带有“捷径连接 (shortcut connections)”的前馈神经网络来实现 (图 2)。捷径连接 [2, 34, 49] 是指跳过一个或多个网络层的连接。在我们的模型中，捷径连接仅执行恒等映射，并将其输出与堆叠层的输出相加 (图 2)。恒等捷径连接不会增加额外的参数，也不会增加计算复杂度。整个网络仍然可以通过带有反向传播的随机梯度下降 (SGD) 进行端到端训练，并且可以使用常见的深度学习库 (例如 Caffe [19]) 轻松实现，而无需修改优化器。

我们在 ImageNet [36] 数据集上进行了全面的实验，以展示退化问题并评估我们提出的方法。实验结果表明：1) 我们极深的残差网络易于优化，而对应的“普通”网络 (即简单地堆叠网络层) 在深度增加时会表现出更高的训练误差；2) 我们的深度残差网络能够轻松地大幅增加的网络深度中获得准确率提升，其结果明显优于之前的网络。

在 CIFAR-10 数据集 [20] 上也观察到了类似的现象，这表明优化困难以及我们方法所带来的效果并不仅仅局限于某一个特定的数据集。我们在该数据集上成功训练了超过 100 层的模型，并进一步探索了超过 1000 层的网络模型。

在 ImageNet 分类数据集 [36] 上，我们通过极深的残差网络取得了优秀的结果。我们的 152 层残差网络是目前在 ImageNet 上提出的最深网络，同时其复杂度仍低于 VGG 网络 [41]。我们的集成模型在 ImageNet 测试集上取得了 3.57% 的 top-5 错误率，并赢得了 ILSVRC 2015 分类竞赛的第一名。极深网络所学习到的表示在其他识别任务上也具有出色的泛化性能，并使我们进一步在 ILSVRC 和 COCO 2015 竞赛中的以下任务中获得第一名：ImageNet 检测、ImageNet 定位、COCO 检测以及 COCO 分割。这些强有力的证据表明，残差学习原理具有通用性，我们认为它同样适用于其他视觉问题以及非视觉问题。

2. 相关工作

残差表示 (Residual Representations)。在图像识别领域，VLAD [18] 是一种通过相对于字典 (dictionary) 的残差向量进行编码的表示方法，而 Fisher Vector [30] 可以被表述为 VLAD 的一种概率化版本 [18]。二者都是用于图像检索和分类任务 [4, 48] 的强大浅层表示方法。在向量量化 (vector quantization) 中，已有研究表明，对残差向量进行编码 [17] 比对原始向量进行编码更加有效。

在低层视觉和计算机图形学领域，为了解决偏微分方程 (Partial Differential Equations, PDEs)，广泛使用的多重网格方法 (Multigrid method) [3] 将系统重新表示为多个尺度下的子问题，其中每个子问题负责解决较粗尺度与较细尺度之间的残差解。多重网格方法的一种替代方法是分层基预条件方法 (hierarchical basis preconditioning) [45, 46]，该方法依赖于表示两个尺度之间残差向量的变量。已有研究表明 [3, 45, 46]，这些求解器的收敛速度远快于那些没有利用解的残差特性的标准求解器。这些方法表明，良好的重新表示方式 (reformulation) 或预条件方法 (preconditioning) 能够简化优化过程。

捷径连接 (Shortcut Connections)。促成捷径连接的方法和相关理论 [2, 34, 49] 已经被研究了很长时间。早期训练多层感知机 (MLP) 的一种方法是在网络输入和输出之间添加一个线性层 [34, 49]。在 [44, 24] 中，一些中间层被直接连接到辅助分类器，以解决梯度消失/梯度爆炸问题。[39, 38, 31, 47] 中的论文提出了利用捷径连接实现的方法，用于对层响应 (layer responses)、梯度 (gradients) 以及传播误差 (propagated errors) 进行中心化处理。在 [44] 中，一个 “inception” 层由一个捷径分支和几个更深层的分支组成。

与我们的工作同时进行的研究中，“高速公路网络 (highway networks)” [42, 43] 提出了带有门控函数 (gating functions) [15] 的捷径连接。这些门控函数依赖于数据并且包含参数，而我们的恒等捷径连接不包含任何参数。当一个门控捷径被 “关闭” (即趋近于零) 时，高速公路网络中的层表示的是非残差函数。相比之下，我们提出的方法始终学习残差函数；我们的恒等捷径连接永远不会被关闭，所有信息始终能够直接传递，同时网络额外学习需要拟合的残差函数。此外，高速公路网络尚未证明在极大增加网络深度 (例如超过 100 层) 时能够获得准确率提升。

3. 深度残差学习 (Deep Residual Learning)

3.1 残差学习 (Residual Learning)

考虑将 $H(x)$ 看作一个需要由若干个堆叠层 (不一定是整个网络) 拟合的底层映射，其中 x 表示这些层中第一个层的输入。如果假设多个非线性层能够渐近逼近复杂函数²，那么等价地也可以假设它们能够渐近逼近残差函数，即 $H(x) - x$ (假设输入和输出具有相同的维度)。因此，我们不再期望堆叠层去逼近 $H(x)$ ，而是明确地让这些层去逼近一个残差函数 $F(x) := H(x) - x$ 。原始函数因此变为 $F(x) + x$ 。尽管根据上述假设，这两种形式都应该能够渐近逼近所需的函数，但它们的学习难易程度可能存在差异。

这种重新表示方式的提出，源于退化问题中反直觉的现象 (图 1，左)。正如我们在引言中讨论的，如果新增的层可以被构造成恒等映射，那么更深的模型的训练误差应该不会高于其较浅模型对应的训练误差。退化问题表明，当前的优化方法可能难以通过多个非线性层去逼近恒等映射。采用残差学习重新表示后，如果恒等映射是最优解，那么优化方法只需要简单地将多个非线性层的权重逐渐趋近于零，即可逼近恒等映射。

就是个 $F(x) = H(x) - x$ ，理论，实践均可行
还如

数字化

跳跃连接 VS 捷径连接 (✓)

本层只学习用 0 拟合 map

少偏差，更集中
数据中心移到 0

同时执行多个特征提取，最终融合结果

$$\text{跳: } y = f(x) \cdot H(x) + (1 - f(x)) \cdot x$$

$$\text{捷: } y = F(x) + x$$

始终并行进行


$$y = f(x) \cdot H(x) + (1 - f(x)) \cdot x$$

$f(x)$ 门控函数
 x : shortcut 恒等的信号

在实际情况下，恒等映射不太可能是最优解，但我们的重新表示方法可能有助于对问题进行预条件化（preconditioning）。如果最优函数更接近于恒等映射，而不是零映射，那么优化器在以恒等映射为参考的情况下寻找偏移量，会比直接学习一个全新的函数更加容易。我们通过实验（图 7）表明，学习得到的残差函数通常具有较小的响应值，这说明恒等映射能够提供一种合理的预条件化方式。

3.2 通过捷径连接的恒等映射


我们将残差学习应用于每几个堆叠层中。图 2 展示了一个构建模块（building block）。形式上，在本文中我们考虑如下定义的构建模块：

$$y = F(x, \{W_i\}) + x.$$


其中， x 和 y 分别表示所考虑层的输入向量和输出向量。函数 $F(x, \{W_i\})$ 表示需要学习的残差映射。对于图 2 中具有两层的示例， $F = W_2\sigma(W_1x)$ ，其中 σ 表示 ReLU [29]，为了简化符号表示，省略了偏置项。运算 $F + x$ 通过捷径连接和逐元素相加（element-wise addition）来实现。我们在相加操作之后采用第二个非线性激活函数（即 $\sigma(y)$ ，见图 2）。

公式（1）中的捷径连接既不会引入额外的参数，也不会增加计算复杂度。这一点不仅在实际应用中具有吸引力，而且对于我们比较普通网络（plain networks）和残差网络（residual networks）来说也非常重要。我们可以公平地比较两类网络，因为它们同时具有相同数量的参数、相同的深度、相同的宽度以及相同的计算成本（除了可以忽略不计的逐元素相加操作）。


在公式（1）中， x 和 F 的维度必须相等。如果两者维度不一致（例如改变输入/输出通道数时），我们可以通过捷径连接执行线性投影 W_s 来匹配维度：

$$y = F(x, \{W_i\}) + W_s x.$$


我们也可以在公式（1）中使用一个方阵形式的 W_s 。但是，我们将通过实验表明，恒等映射已经足以解决退化问题，并且这种方式更加经济有效，因此 W_s 仅在需要匹配维度时使用。

残差函数 F 的形式具有灵活性。本文中的实验采用了包含两层或三层的函数 F （图 5），但也可以使用更多层。然而，如果 F 仅包含单层，那么公式（1）类似于一个线性层 $y = W_1x + xv$ ，对于这种形式，我们并没有观察到其具有优势。

我们还需要注意，尽管上述符号表示为了简化而针对全连接层进行描述，但它们同样适用于卷积层。函数 $F(x, \{W_i\})$ 可以表示多个卷积层。逐元素相加操作是在两个特征图（feature maps）之间进行的，并且按照通道（channel）逐通道执行。




3.3 网络架构

不同 channel 代表不同特征
同一个特征才相加

我们测试了各种普通网络（plain nets）和残差网络（residual nets），并观察到了稳定一致的现象。为了便于讨论，我们下面介绍两个用于 ImageNet 的模型作为示例。


提出, depth 降维

VGG-19




普通

34-layer plain



残差

34-layer residual






图 3. 用于 ImageNet 的网络架构示例。左：作为参考的 VGG-19 模型 [41]（196 亿次 FLOPs）。中：具有 34 个参数层的普通网络（36 亿次 FLOPs）。右：具有 34 个参数层的残差网络（36 亿次 FLOPs）。其中虚线表示用于增加维度的捷径连接。表 1 展示了更多细节以及其他变体。

普通网络（Plain Network）。我们的普通网络基线模型（图 3，中间）主要受到 VGG 网络思想 [41]（图 3，左）的启发。卷积层大多采用 3×3 卷积核，并遵循两个简单的设计规则：（i）对于相同输出特征图尺寸的层，采用相同数量的卷积核；（ii）如果特征图尺寸减半，则卷积核数量增加一倍，以保持每层的时间复杂度不变。我们通过步长为 2 的卷积层直接进行下采样。网络最后连接一个全局平均池化层以及一个具有 1000 个输出类别、使用 softmax 的全连接层。在图 3（中间）所示的网络中，具有权重参数的层总数为 34 层。

值得注意的是，与 VGG 网络 [41]（图 3，左）相比，我们的模型采用了更少的卷积核，并且具有更低的复杂度。我们的 34 层基准网络具有 36 亿次 FLOPs（浮点运算次数，multiply-adds），仅为 VGG-19（196 亿次 FLOPs）的 18%。

残差网络（Residual Network）。基于上述普通网络，我们加入捷径连接（图 3，右），从而将该网络转变为对应的残差版本。当输入和输出具有相同维度时，可以直接使用恒等捷径连接（公式（1），图 3 中的实线捷径）。当维度增加时（图 3 中的虚线捷径），我们考虑两种方案：（A）捷径仍然执行恒等映射，并通过额外填充零值来增加维度。该方案不会引入额外参数；（B）使用公式（2）中的投影捷径来匹配维度（通过 1×1 卷积实现）。对于这两种方案，当捷径连接跨越两个不同尺寸的特征图时，均采用步长为 2 的操作。

对 x 维度用 0 补

$$F(x, \{w_i\}) + w_s x$$

3.4 实现

我们在 ImageNet 上的实现遵循了 [21,41] 中的方法。图像的短边会被随机调整到 [256,480][256,480] 范围内，以进行尺度增强 [41]。然后，从图像或其水平翻转版本中随机裁剪一个 224×224 的区域，并减去每个像素的均值 [21]。我们采用了 [21] 中的标准颜色增强方法。按照 [16] 的方法，我们在每个卷积操作之后、激活函数之前采用批量归一化 (BN) [16]。我们按照 [13] 中的方法初始化权重，并从头开始训练所有普通网络和残差网络。我们使用 mini-batch 大小为 256 的随机梯度下降 (SGD) 进行训练。学习率初始设置为 0.1，当误差不再下降时将学习率降低 10 倍，模型最多训练 60×10^4 次迭代。我们使用 0.0001 的权重衰减和 0.9 的动量。按照 [16] 中的方法，我们没有使用 dropout [14]。

有趣的是，在对比实验中，我们采用了标准的 10-crop 测试方法 [21]。为了获得最佳结果，我们采用了 [41,13] 中的全卷积形式，并对多个尺度下的预测分数进行平均（图像会被调整大小，使其短边长度分别为 {224, 256, 384, 480, 640}）。

4. 实验

4.1 ImageNet 分类

我们在 ImageNet 2012 分类数据集 [36] 上评估了我们的方法，该数据集包含 1000 个类别。模型在 128 万张训练图像上进行训练，并在 5 万张验证图像上进行评估。我们还在 10 万张测试图像上获得了最终结果，该结果由测试服务器进行报告。我们评估了 top-1 和 top-5 错误率。

普通网络 (Plain Networks)。我们首先评估了 18 层和 34 层普通网络。34 层普通网络如图 3（中间）所示，18 层普通网络具有类似的结构。详细的网络架构请参见表 1。

表 2 中的结果表明，更深的 34 层普通网络相比更浅的 18 层普通网络具有更高的验证误差。为了揭示其中的原因，我们在图 4（左）中比较了它们在训练过程中的训练误差和验证误差。我们观察到了退化问题——尽管 18 层普通网络的解空间是 34 层普通网络解空间的子空间，但 34 层普通网络在整个训练过程中始终具有更高的训练误差。

表 1. ImageNet 网络架构。构建模块以括号形式表示（另见图 5），括号后的数字表示堆叠的模块数量。下采样通过步长为 2 的 conv3_1、conv4_1 和 conv5_1 卷积层实现。

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9




图 4. 在 ImageNet 上的训练结果。细曲线表示训练误差，粗曲线表示中心裁剪（center crops）验证误差。左：18 层和 34 层普通网络。右：18 层和 34 层 ResNet。在该图中，残差网络相比对应的普通网络没有额外参数。

表 2. ImageNet 验证集上的 top-1 错误率（%，10-crop 测试）。在这里，ResNet 相比对应的普通网络没有额外参数。图 4 展示了训练过程。

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	25.03

我们认为，这种优化困难不太可能是由梯度消失导致的。这些普通网络采用了 BN [16] 进行训练，BN 可以确保前向传播的信号具有非零方差。我们还验证了在使用 BN 的情况下，反向传播的梯度也具有健康的范数。因此，无论是前向传播信号还是反向传播信号都没有消失。事实上，34 层普通网络仍然能

未来挑战：优化器的影响

够达到具有竞争力的准确率（表 3），这表明优化器在一定程度上能够发挥作用。我们推测，深层普通网络可能具有指数级降低的收敛速度，这会影响训练误差的降低³。这种优化困难产生的原因将在未来进行研究。

残差网络（Residual Networks）。接下来，我们评估了 18 层和 34 层残差网络（ResNets）。基准网络结构与上述普通网络相同，区别在于按照图 3（右）所示，在每一对 3×3 卷积层上增加了一个捷径连接。在第一次比较中（表 2 和图 4 右），我们对所有捷径连接采用恒等映射，并在增加维度时采用零填充（方案 A）。因此，与对应的普通网络相比，它们没有增加额外参数。

从表 2 和图 4 中，我们得到三个主要观察结果。首先，在采用残差学习后，情况发生了逆转——34 层 ResNet 的性能优于 18 层 ResNet（提升了 2.8%）。更重要的是，34 层 ResNet 表现出了明显更低的训练误差，并且能够很好地泛化到验证数据上。这表明，在这种情况下，退化问题得到了有效解决，并且我们能够通过增加网络深度获得准确率提升。

其次，与对应的普通网络相比，34 层 ResNet 将 top-1 错误率降低了 3.5%（表 2），这一结果来源于训练误差的成功降低（图 4 右图与左图对比）。这一比较验证了残差学习在极深网络系统中的有效性。

表 3. ImageNet 验证集上的错误率（%，10-crop 测试）。VGG-16 的结果基于我们的测试。ResNet-50/101/152 采用方案 B，即仅在增加维度时使用投影捷径连接。

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	21.43	5.71

表 4. ImageNet 验证集上的单模型结果错误率（%）（除带 + 标记的结果是在测试集上报告的）。

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC'14)	-	8.43 [†]
GoogLeNet [44] (ILSVRC'14)	-	7.89
VGG [41] (v5)	24.4	7.1
PreLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	19.38	4.49

表 5. 集成模型 (ensembles) 的错误率 (%)。top-5 错误率是在 ImageNet 测试集上测得，并由测试服务器报告。

method	top-5 err. (test)
VGG [41] (ILSVRC'14)	7.32
GoogLeNet [44] (ILSVRC'14)	6.66
VGG [41] (v5)	6.8
PreLU-net [13]	4.94
BN-inception [16]	4.82
ResNet (ILSVRC'15)	3.57

最后，我们还注意到，18 层普通网络和残差网络具有相近的准确率（表 2），但 18 层 ResNet 收敛速度更快（图 4 右图与左图对比）。当网络“不是过深”（这里指 18 层）时，当前的 SGD 优化器仍然能够为普通网络找到较好的解。在这种情况下，ResNet 通过在训练早期阶段提供更快的收敛速度，降低了优化难度。

恒等映射与投影捷径连接 (Identity vs. Projection Shortcuts)。我们已经证明，不包含参数的恒等捷径连接有助于网络训练。接下来，我们研究投影捷径连接（公式 (2)）。在表 3 中，我们比较了三种方案：（A）当维度增加时采用零填充捷径连接，并且所有捷径连接都不包含参数（与表 2 和图 4

$$y = F(x, \{w_i\}) + x$$

右图相同)；(B) 当维度增加时采用投影捷径连接，而其他捷径连接采用恒等映射；(C) 所有捷径连接均采用投影连接。




图 5. 用于 ImageNet 的更深残差函数 F。左：如图 3 所示，ResNet-34 中的构建模块（位于 56×56 特征图上）。右：用于 ResNet-50/101/152 的“瓶颈”（bottleneck）构建模块。

表 3 显示，这三种方案都明显优于对应的普通网络。方案 B 略优于方案 A。我们认为，这是因为方案 A 中通过零填充增加的维度实际上没有进行残差学习。方案 C 略优于方案 B，我们将其归因于许多（13 个）投影捷径连接所引入的额外参数。然而，方案 A、B、C 之间的差异很小，这表明投影捷径连接并不是解决退化问题的必要条件。因此，在本文后续实验中，我们不采用方案 C，以减少内存/时间复杂度以及模型规模。恒等捷径连接对于避免增加后文将介绍的瓶颈结构的复杂度尤其重要。

更深的瓶颈结构（Deeper Bottleneck Architectures）。接下来，我们介绍用于 ImageNet 的更深网络。由于考虑到我们能够承担的训练时间，我们将构建模块修改为瓶颈结构设计⁴。对于每个残差函数 F，我们使用由 3 层组成的堆叠结构，而不是 2 层结构（图 5）。这三层分别为 1×1 、 3×3 和 1×1 卷积，其中 1×1 卷积层负责降低维度，然后再增加（恢复）维度，使得 3×3 卷积层成为具有更小输入/输出维度的瓶颈层。图 5 展示了一个示例，其中两种设计具有相近的时间复杂度。

不包含参数的恒等捷径连接对于瓶颈结构尤为重要。如果将图 5（右）中的恒等捷径连接替换为投影连接，可以证明时间复杂度和模型规模都会增加一倍，因为该捷径连接连接的是两个高维端。因此，对于瓶颈结构设计而言，恒等捷径连接能够带来更加高效的模型。

50 层 ResNet：我们将 34 层网络中的每个两层结构块替换为这种三层瓶颈结构，从而得到一个 50 层 ResNet（表 1）。在增加维度时，我们采用方案 B。该模型具有 38 亿次 FLOPs。

101 层和 152 层 ResNet：我们通过使用更多的三层结构块构建了 101 层和 152 层 ResNet（表 1）。值得注意的是，尽管网络深度显著增加，152 层 ResNet（113 亿次 FLOPs）的复杂度仍然低于 VGG-16/19 网络（分别为 153 亿次/196 亿次 FLOPs）。

50 层、101 层和 152 层 ResNet 的准确率都明显高于 34 层 ResNet（表 3 和表 4）。我们没有观察到退化问题，因此能够从显著增加的网络深度中获得明显的准确率提升。深度带来的优势体现在所有评估指标上（表 3 和表 4）。

与当前最先进方法的比较 (Comparisons with State-of-the-art Methods)。在表 4 中，我们与之前最佳的单模型结果进行了比较。我们的 34 层 ResNet 基准模型已经取得了非常具有竞争力的准确率。我们的 152 层 ResNet 单模型在验证集上的 top-5 错误率为 4.49%。这一单模型结果超过了之前所有的集成模型结果（表 5）。我们将六个不同深度的模型组合成一个集成模型（在提交时仅包含两个 152 层模型）。该模型在测试集上取得了 3.57% 的 top-5 错误率（表 5）。这一结果获得了 ILSVRC 2015 竞赛的第一名。

4.2 CIFAR-10 与分析

我们在 CIFAR-10 数据集 [20] 上进行了更多研究，该数据集包含 5 万张训练图像和 1 万张测试图像，共分为 10 个类别。我们在训练集上进行训练，并在测试集上进行评估。我们的重点是研究极深网络的行为，而不是追求最先进的结果，因此我们有意采用如下简单的网络结构。

普通网络和残差网络结构遵循图 3（中间/右侧）所示的形式。网络输入为 32×32 的图像，并减去每个像素的均值。第一层为 3×3 卷积层。随后，我们在尺寸分别为 $\{32, 16, 8\}$ 的特征图上使用由 n 个 3×3 卷积层组成的堆叠结构，其中每种特征图尺寸对应 $2n$ 个卷积层。卷积核数量分别为 $\{16, 32, 64\}$ 。下采样通过步长为 2 的卷积实现。网络最后连接一个全局平均池化层、一个 10 类全连接层以及 softmax 层。总共有 $6n+2$ 个带权重的堆叠层。下面的表格总结了该网络结构：

output map size	32×32	16×16	8×8
# layers	$1+2n$	$2n$	$2n$
# filters	16	32	64

当使用捷径连接时，它们被连接到每一对 3×3 卷积层上（总共有 $3n$ 个捷径连接）。在该数据集上，我们在所有情况下都使用恒等捷径连接（即方案 A），因此我们的残差模型与对应的普通模型具有完全相同的深度、宽度以及参数数量。

表 6. CIFAR-10 测试集上的分类错误率。所有方法均采用数据增强。对于 ResNet-110，我们运行了 5 次实验，并按照 [43] 的方式报告“最佳结果（均值 $\pm$ 标准差）”。

method			error (%)
Maxout [10]			9.38
NIN [25]			8.81
DSN [24]			8.22
	# layers	# params	
FitNet [35]	19	2.5M	8.39
Highway [42, 43]	19	2.3M	7.54 (7.72 $\pm$ 0.16)
Highway [42, 43]	32	1.25M	8.80
ResNet	20	0.27M	8.75
ResNet	32	0.46M	7.51
ResNet	44	0.66M	7.17
ResNet	56	0.85M	6.97
ResNet	110	1.7M	6.43 (6.61 $\pm$ 0.16)
ResNet	1202	19.4M	7.93

我们使用 0.0001 的权重衰减和 0.9 的动量，并采用 [13] 中的权重初始化方法以及 BN [16]，但不使用 dropout。这些模型在两块 GPU 上以 128 的 mini-batch 大小进行训练。我们将初始学习率设置为 0.1，在 32k 次和 48k 次迭代时分别将学习率降低 10 倍，并在 64k 次迭代时终止训练，该训练策略是在 45k/5k 的训练集/验证集划分上确定的。训练时，我们采用 [24] 中简单的数据增强方法：在图像每一侧填充 4 个像素，然后从填充后的图像或其水平翻转版本中随机裁剪一个 32×32 的区域。测试时，我们只评估原始 32×32 图像的单视角结果。

我们比较了 $n = \{3, 5, 7, 9\}$ 的情况，分别得到 20 层、32 层、44 层和 56 层网络。图 6（左）展示了普通网络的表现。随着网络深度增加，深层普通网络受到退化问题的影响，并且在网络变得更深时表现出更高的训练误差。这一现象与 ImageNet（图 4，左）以及 MNIST（见 [42]）上的结果类似，表明这种优化困难是一个普遍存在的基本问题。

图 6（中间）展示了 ResNet 的表现。同样类似于 ImageNet 上的实验结果（图 4，右），我们的 ResNet 能够克服优化困难，并且在网络深度增加时表现出准确率提升。

我们进一步探索了 $n=18$ 的情况，从而得到一个 110 层 ResNet。在这种情况下，我们发现初始学习率 0.1 略大，导致网络难以开始收敛⁵。因此，我们使用 0.01 的学习率进行预热训练（warm up），直到训练误差低于 80%（大约 400 次迭代），然后恢复到 0.1 并继续训练。之后的学习率调整策略与之前相同。这个 110 层网络能够很好地收敛（图 6，中间）。它的参数数量少于其他深层窄网络，例如 FitNet [35] 和 Highway [42]（表 6），但仍取得了接近当前最优水平的结果（6.43%，表 6）。




图 6. CIFAR-10 上的训练结果。虚线表示训练误差，粗线表示测试误差。**左**：普通网络。普通网络 110 层的误差高于 60%，因此未在图中显示。**中**：ResNet。**右**：具有 110 层和 1202 层的 ResNet。




图 7. CIFAR-10 上层响应的标准差 (std)。这些响应是每个 3×3 层的输出，即经过 BN 之后、非线性操作之前的输出。**上**：按照层原本的顺序展示这些层。**下**：按照响应值从大到小进行排序后展示。

层响应分析 (Analysis of Layer Responses)。图 7 展示了层响应的标准差 (std)。这些响应是每个 3×3 层的输出，即经过 BN 之后、其他非线性操作 (ReLU/相加) 之前的输出。对于 ResNet 而言，这种分析反映了残差函数的响应强度。图 7 表明，ResNet 的响应通常比对应的普通网络更小。这些结果支持了我们的基本动机 (第 3.1 节)，即残差函数通常可能比非残差函数更接近于零。我们还注意到，更深的 ResNet 具有更小幅度的响应，这一点可以通过图 7 中 ResNet-20、ResNet-56 和 ResNet-110 之间的比较得到证明。当网络包含更多层时，ResNet 中的单个层往往对信号进行更小程度的修改。

探索超过 1000 层的网络 (Exploring Over 1000 layers)。我们探索了一个超过 1000 层的极深模型。我们设置 $n=200$ ，从而得到一个 1202 层的网络，并按照上述方法进行训练。我们的方法没有表现

出优化困难，并且这个 1202 层网络能够达到低于 0.1% 的训练误差（图 6，右）。它的测试误差仍然相当不错（7.93%，表 6）。

但是，对于这种极深模型，仍然存在一些尚未解决的问题。这个 1202 层网络的测试结果比我们的 110 层网络更差，尽管两者具有相近的训练误差。我们认为这是由于过拟合导致的。对于这个较小的数据集而言，1202 层网络可能过于庞大（包含 1940 万个参数）。为了在该数据集上获得最佳结果（[10,25,24,35]），通常会采用 maxout [10] 或 dropout [14] 等强正则化方法。

表 7. 使用**基准** Faster R-CNN 在 PASCAL VOC 2007/2012 测试集上的目标检测 mAP（%）。更好的结果请参见表 10 和表 11。

training data	07+12	07++12
test data	VOC 07 test	VOC 12 test
VGG-16	73.2	70.4
ResNet-101	76.4	73.8

表 8. 使用**基准** Faster R-CNN 在 COCO 验证集上的目标检测 mAP（%）。更好的结果请参见表 9。

metric	mAP@.5	mAP@[.5, .95]
VGG-16	41.5	21.2
ResNet-101	48.4	27.2

在本文中，我们没有使用 maxout/dropout，而是通过设计深而窄的网络结构来简单地施加正则化，同时避免干扰我们对优化困难问题的研究重点。然而，与更强的正则化方法结合可能会进一步提升结果，这将作为未来的研究方向。

4.3 PASCAL 和 MS COCO 上的目标检测

我们的方法在其他识别任务上也具有良好的泛化性能。表 7 和表 8 展示了我们在 PASCAL VOC 2007 和 2012 [5] 以及 COCO [26] 数据集上的目标检测基线结果。我们采用 Faster R-CNN [32] 作为检测方法。在这里，我们关注的是将 VGG-16 [41] 替换为 ResNet-101 所带来的性能提升。使用这两个模型的检测实现方式（见附录）完全相同，因此性能提升只能归因于更优的网络结构。尤其值得注意的是，在具有挑战性的 COCO 数据集上，我们在 COCO 的标准评价指标（ $mAP@[.5, .95]$ ）上提升了 6.0%，即相对提升了 28%。这一提升完全来自于学习得到的特征表示。

基于深度残差网络，我们在 ILSVRC 和 COCO 2015 竞赛的多个任务中获得了第一名：包括 ImageNet 目标检测、ImageNet 图像定位、COCO 目标检测以及 COCO 图像分割。具体细节见附录。

A. 目标检测基线 (Object Detection Baselines)

在本节中，我们介绍一种基于基准 Faster R-CNN [32] 系统的检测方法。模型首先使用 ImageNet 分类模型进行初始化，然后在目标检测数据上进行微调 (fine-tuning)。在 ILSVRC 和 COCO 2015 目标检测竞赛期间，我们实验了 ResNet-50/101。

不同于 [32] 中使用的 VGG-16，我们的 ResNet 没有隐藏的全连接层 (fc layers)。我们采用了“卷积特征图上的网络” (Networks on Conv feature maps, NoC) [33] 的思想来解决这一问题。我们使用那些在图像上的步长不超过 16 个像素的层 (即 conv1、conv2_x、conv3_x 和 conv4_x，在 ResNet-101 中总共有 91 个卷积层；见表 1) 计算整张图像共享的卷积特征图。我们认为这些层类似于 VGG-16 中的 13 个卷积层，通过这种方式，ResNet 和 VGG-16 都具有相同总步长 (16 个像素) 的卷积特征图。这些层由区域候选网络 (Region Proposal Network, RPN，生成 300 个候选区域) [32] 和 Fast R-CNN 检测网络 [7] 共享。在 conv5_1 之前执行 RoI pooling [7]。对于经过 RoI pooling 得到的特征，conv5_x 及之后的所有层都会针对每个区域采用，它们所起的作用类似于 VGG-16 中的全连接层。最终的分类层被替换为两个并行的层 (classification 和 bounding box regression [7])。

对于 BN 层的使用，在预训练完成后，我们在 ImageNet 训练集上计算每一层的 BN 统计量 (均值和方差)。随后，在目标检测微调过程中固定 BN 层。因此，BN 层变成具有固定偏移量和尺度的线性激活，并且 BN 统计量不会随着微调过程而更新。我们固定 BN 层主要是为了减少 Faster R-CNN 训练过程中的内存消耗。

PASCAL VOC

遵循 [7,32] 的方法，对于 PASCAL VOC 2007 测试集，我们使用 VOC 2007 中的 5k 张 trainval 图像以及 VOC 2012 中的 16k 张 trainval 图像进行训练 (“07+12”)。对于 PASCAL VOC 2012 测试集，我们使用 VOC 2007 中的 10k 张 trainval+test 图像以及 VOC 2012 中的 16k 张 trainval 图像进行训练 (“07++12”)。训练 Faster R-CNN 时的超参数与 [32] 中保持一致。表 7 展示了实验结果。ResNet-101 相比 VGG-16 将 mAP 提升了超过 3%。这一提升完全来源于 ResNet 学习到的更优特征表示。

MS COCO

MS COCO 数据集 [26] 包含 80 个目标类别。我们评估了 PASCAL VOC 指标 ($mAP@IoU = 0.5$) 以及标准 COCO 指标 ($mAP@IoU = .5 : .95$)。我们使用训练集中的 8 万张图像进行训练，并使用验证集中的 4 万张图像进行评估。我们在 COCO 上的检测系统与 PASCAL VOC 中的系统类似。我们使用 8-GPU 实现来训练 COCO 模型，因此 RPN 阶段的 mini-batch 大小为 8 张图像 (即每个 GPU 处理 1 张图像)，Fast R-CNN 阶段的 mini-batch 大小为 16 张图像。RPN 阶段和 Fast R-CNN 阶段均训练 240k 次迭代，学习率设置为 0.001，随后再以 0.0001 的学习率训练 80k 次迭代。表 8 展示了 MS COCO 验证集上的结果。ResNet-101 相比 VGG-16 在 $mAP@[.5, .95]$ 指标上提升了 6%，即相对提升了 28%，这一提升完全来自于更优网络学习到的特征。值得注意的是， $mAP@[.5, .95]$ 的绝对提升 (6.0%) 几乎与 $mAP@.5$ 的提升 (6.9%) 一样大。这表明，更深的网络不仅能够提升目标识别能力，也能够提升目标定位能力。

B. 目标检测改进 (Object Detection Improvements)

为了完整起见，我们报告了在竞赛中采用的改进方法。这些改进都基于深度特征，因此应该能够受益于残差学习。

MS COCO

边界框优化（Box refinement）。我们的边界框优化方法部分遵循了 [6] 中的迭代定位方法。在 Faster R-CNN 中，最终输出的是一个经过回归得到的边界框，它与原始候选框（proposal box）不同。因此，在推理阶段，我们从回归后的边界框中重新池化（pool）一个新的特征，并获得新的分类得分以及新的回归边界框。我们将这 300 个新的预测结果与原始的 300 个预测结果进行组合。随后，在预测边界框的并集上使用交并比（IoU）阈值为 0.3 的非极大值抑制（NMS）[8]，然后进行边界框投票（box voting）[6]。边界框优化能够将 mAP 提升约 2 个百分点（表 9）。

全局上下文（Global context）。我们在 Fast R-CNN 阶段融合了全局上下文信息。给定整张图像的卷积特征图，我们通过全局空间金字塔池化（global Spatial Pyramid Pooling）[12]（采用“单层”金字塔）对特征进行池化，该操作可以通过将整张图像的边界框作为 RoI 来实现类似于 RoI pooling 的效果。池化后的特征被输入 RoI 后续层，以获得全局上下文特征。然后，该全局特征与原始的区域特征进行拼接，并输入并行的分类层和边界框回归层。这个新的结构采用端到端方式进行训练。全局上下文能够将 $mAP@.5$ 提升约 1 个百分点（表 9）。

多尺度测试（Multi-scale testing）。上述所有结果都采用了与 [32] 相同的单尺度训练/测试方式，其中图像的短边长度设置为 $s=600s=600$ 像素。多尺度训练/测试方法已经在 [12,7] 中通过从特征金字塔中选择尺度实现，并在 [33] 中通过使用 maxout 层实现。在我们当前的实现中，我们按照 [33] 的方法进行了多尺度测试；由于时间有限，我们没有进行多尺度训练。此外，我们只对 Fast R-CNN 阶段进行了多尺度测试（尚未对 RPN 阶段进行多尺度测试）。对于一个已经训练好的模型，我们在图像金字塔上计算卷积特征图，其中图像的短边长度取值为 $s \in \{200, 400, 600, 800, 1000\}$

表 9. 使用 Faster R-CNN 和 ResNet-101 在 MS COCO 上进行目标检测改进的结果。

training data	COCO train		COCO trainval	
test data	COCO val		COCO test-dev	
mAP	@.5	@[.5, .95]	@.5	@[.5, .95]
baseline Faster R-CNN (VGG-16)	41.5	21.2		
baseline Faster R-CNN (ResNet-101)	48.4	27.2		
+box refinement	49.9	29.9		
+context	51.1	30.0	53.3	32.2
+multi-scale testing	53.8	32.5	55.7	34.9
ensemble			59.0	37.4

表 10. PASCAL VOC 2007 测试集上的检测结果。基线方法为 Faster R-CNN 系统。系统

“baseline+++” 包含表 9 中的边界框优化（box refinement）、上下文信息（context）以及多尺度测试（multi-scale testing）。

system	net	data	mAP	areo	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
baseline	VGG-16	07+12	73.2	76.5	79.0	70.9	65.5	52.1	83.1	84.7	86.4	52.0	81.9	65.7	84.8	84.6	77.5	76.7	38.8	73.6	73.9	83.0	72.6
baseline	ResNet-101	07+12	76.4	79.8	80.7	76.2	68.3	55.9	85.1	85.3	89.8	56.7	87.8	69.4	88.3	88.9	80.9	78.4	41.7	78.6	79.8	85.3	72.0
baseline+++	ResNet-101	COCO+07+12	85.6	90.0	89.6	87.8	80.8	76.1	89.9	89.9	89.6	75.5	90.0	80.7	89.6	90.3	89.1	88.7	65.4	88.1	85.6	89.0	86.8

表 11. PASCAL VOC 2012 测试集上的检测结果

(<http://host.robots.ox.ac.uk:8080/leaderboard/displaylb.php?challengeid=11&compid=4>)。基线方法为 Faster R-CNN 系统。系统 “baseline+++” 包含表 9 中的边界框优化（box refinement）、上下文信息（context）以及多尺度测试（multi-scale testing）。

system	net	data	mAP	areo	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
baseline	VGG-16	07++12	70.4	84.9	79.8	74.3	53.9	49.8	77.5	75.9	88.5	45.6	77.1	55.3	86.9	81.7	80.9	79.6	40.1	72.6	60.9	81.2	61.5
baseline	ResNet-101	07++12	73.8	86.5	81.6	77.2	58.0	51.0	78.6	76.6	93.2	48.6	80.4	59.0	92.1	85.3	84.8	80.7	48.1	77.3	66.5	84.7	65.6
baseline+++	ResNet-101	COCO+07++12	83.8	92.1	88.4	84.8	75.9	71.4	86.3	87.8	94.2	66.8	89.4	69.2	93.9	91.9	90.9	89.6	67.9	88.2	76.8	90.3	80.0

我们按照 [33] 的方法，从图像金字塔中选择两个相邻尺度。RoI pooling 以及后续层在这两个尺度对应的特征图上执行 [33]，然后通过类似于 [33] 中的方法使用 maxout 进行融合。多尺度测试能够将 mAP 提升超过 2 个百分点（表 9）。

使用验证数据（Using validation data）。接下来，我们使用包含 8 万张训练图像和 4 万张验证图像的 trainval 数据集进行训练，并使用 2 万张 test-dev 数据集进行评估。test-dev 数据集没有公开可用的真实标注（ground truth），结果由评测服务器报告。在这种设置下，结果为 $mAP@.5 = 55.7\%$ ，以及 $mAP@[.5, .95] = 34.9\%$ （表 9）。这是我们的单模型结果。

集成模型（Ensemble）。在 Faster R-CNN 中，系统被设计为同时学习区域候选框（region proposals）以及目标分类器，因此可以通过集成模型同时提升这两个任务的性能。我们使用一个集成模型生成候选区域，然后将这些候选区域的并集输入由多个区域分类器组成的集成模型进行处理。表 9 展示了基于 3 个网络集成得到的结果。在 test-dev 数据集上，该方法的 mAP 达到 59.0%， $mAP@[.5, .95]$ 达到 37.4%。这一结果使我们在 COCO 2015 目标检测任务中获得了第一名。

PASCAL VOC

我们基于上述模型重新研究了 PASCAL VOC 数据集。我们使用在 COCO 数据集上训练得到的单模型（表 9 中 $mAP@.5 = 55.7\%$ ），并在 PASCAL VOC 数据集上对该模型进行微调。边界框优化（box refinement）、上下文信息（context）以及多尺度测试（multi-scale testing）带来的改进也被采用。

表 12. 我们在 ImageNet 检测数据集上的结果（mAP，%）。我们的检测系统为 Faster R-CNN [32]，采用表 9 中的改进方法，并使用 ResNet-101 作为网络。

	val2	test
GoogLeNet [44] (ILSVRC'14)	-	43.9
our single model (ILSVRC'15)	60.5	58.8
our ensemble (ILSVRC'15)	63.6	62.1

通过这些方法，我们在 PASCAL VOC 2007 上达到了 85.6% 的 mAP（表 10），并在 PASCAL VOC 2012 上达到了 83.8% 的 mAP（表 11）⁶。PASCAL VOC 2012 上的结果比之前的最佳结果 [6] 高出了 10 个百分点。

ImageNet 检测 (ImageNet Detection)

ImageNet 检测 (DET) 任务包含 200 个目标类别。其准确率通过 mAP@.5 进行评估。我们用于 ImageNet DET 的目标检测算法与表 9 中用于 MS COCO 的算法相同。网络首先在包含 1000 个类别的 ImageNet 分类数据集上进行预训练，然后在 DET 数据集上进行微调。我们按照 [8] 的方法，将验证集划分为两个部分 (val1/val2)。我们使用 DET 训练集和 val1 集对检测模型进行微调，并使用 val2 集进行验证。我们没有使用其他 ILSVRC 2015 数据。在 DET 测试集上，我们基于 ResNet-101 的单模型达到了 58.8% 的 mAP，而由 3 个模型组成的集成模型达到了 62.1% 的 mAP（表 12）。这一结果使我们在 ILSVRC 2015 的 ImageNet 检测任务中获得第一名，并且比第二名高出 8.5 个百分点（绝对提升）。

表 13. ImageNet 验证集上的定位错误率 (%)。在“LOC error on GT class” ([41]) 这一列中，使用真实类别 (ground truth class) 进行定位。在“testing”列中，“1-crop”表示在 224×224 像素的中心裁剪图像上进行测试；“dense”表示密集测试（全卷积测试）以及多尺度测试。

LOC method	LOC network	testing	LOC error on GT CLS	classification network	top-5 LOC error on predicted CLS
VGG's [41]	VGG-16	1-crop	33.1 [41]		
RPN	ResNet-101	1-crop	13.3		
RPN	ResNet-101	dense	11.7		
RPN	ResNet-101	dense		ResNet-101	14.4
RPN+RCNN	ResNet-101	dense		ResNet-101	10.6
RPN+RCNN	ensemble	dense		ensemble	8.9

C. ImageNet 图像定位 (ImageNet Localization)

ImageNet 图像定位 (LOC) 任务 [36] 要求模型同时完成目标分类和目标定位。遵循 [40,41] 的方法，我们假设首先采用图像级分类器预测图像类别标签，而定位算法仅负责根据预测出的类别生成边界

框。我们采用“每类别回归”（per-class regression, PCR）策略 [40,41]，即为每个类别学习一个边界框回归器。我们首先在 ImageNet 分类任务上对网络进行预训练，然后针对定位任务进行微调。网络使用提供的 1000 类 ImageNet 训练集进行训练。

我们的定位算法基于 [32] 中的 RPN（Region Proposal Network，区域候选网络）框架，并进行了少量修改。不同于 [32] 中类别无关（category-agnostic）的设计方式，我们用于定位任务的 RPN 采用每类别（per-class）的形式。该 RPN 最后连接两个并行的 1×1 卷积层，分别用于二分类（cls）和边界框回归（reg），与 [32] 中的设计类似。但不同于 [32]，我们的 cls 和 reg 层都是针对每个类别设计的。具体来说，cls 层具有 1000 维输出，每一维都是一个二元逻辑回归（binary logistic regression），用于预测当前位置是否属于某个目标类别；reg 层具有 $1000 \times 4 \times 1000$ 维输出，其中包含 1000 个类别对应的边界框回归器。与 [32] 相同，我们的边界框回归也是相对于每个位置处多个具有平移不变性的“锚框”（anchor boxes）进行预测。

与 ImageNet 分类训练（第 3.4 节）相同，我们随机采样 224×224 的裁剪区域作为数据增强方式。微调时使用大小为 256 张图像的 mini-batch。为了避免负样本占据主导地位，我们针对每张图像随机采样 8 个 anchor，其中正样本和负样本 anchor 的比例为 1:1 [32]。测试时，网络以全卷积方式应用于整张图像。

表 13 比较了定位结果。遵循 [41]，我们首先使用真实类别标签作为分类预测结果进行“oracle”测试。VGG 论文 [41] 报告，在使用真实类别的情况下，中心裁剪（center-crop）的错误率为 33.1%（表 13）。在相同设置下，我们基于 ResNet-101 的 RPN 方法将中心裁剪错误率显著降低到了 13.3%。这一比较证明了我们框架的优秀性能。通过密集测试（全卷积测试）以及多尺度测试，我们的 ResNet-101 在使用真实类别标签时达到了 11.7% 的错误率。使用 ResNet-101 预测类别（top-5 分类错误率为 4.6%，见表 4）时，top-5 定位错误率为 14.4%。

表 14. ImageNet 数据集上定位错误率（%）与当前最先进方法（state-of-the-art methods）的比较。

method	top-5 localization err	
	val	test
OverFeat [40] (ILSVRC'13)	30.0	29.9
GoogLeNet [44] (ILSVRC'14)	-	26.7
VGG [41] (ILSVRC'14)	26.9	25.3
ours (ILSVRC'15)	8.9	9.0

上述结果仅基于 Faster R-CNN [32] 中的区域候选网络（RPN）。理论上，可以进一步使用 Faster R-CNN 中的检测网络（Fast R-CNN [7]）来提升结果。然而，我们注意到，在该数据集中，一张图像通常只包含一个主要目标，并且候选区域之间高度重叠，因此它们具有非常相似的 RoI pooling 特征。因此，Fast R-CNN [7] 中以图像为中心（image-centric）的训练方式会产生变化较小的样本，这可能不

利于随机训练。受此启发，在当前实验中，我们使用原始的 R-CNN [8] 替代 Fast R-CNN。R-CNN 是一种以 RoI 为中心（RoI-centric）的检测方法。

我们的 R-CNN 实现方式如下。我们首先将上述训练好的每类别 RPN 应用于训练图像，并针对真实类别预测边界框。这些预测框作为依赖类别的候选区域（class-dependent proposals）。对于每张训练图像，我们选取得分最高的 200 个候选区域作为训练样本，用于训练 R-CNN 分类器。图像区域从候选框中裁剪出来，并缩放到 224×224 像素，然后输入分类网络中，与 R-CNN [8] 中的方法相同。该网络的输出包含两个并行的全连接层，分别用于分类（cls）和边界框回归（reg），同样采用每类别形式。这个 R-CNN 网络以 RoI 为中心的方式进行微调，mini-batch 大小设置为 256。测试时，RPN 针对每个预测类别生成得分最高的 200 个候选框，然后使用 R-CNN 网络更新这些候选框的得分和位置。

该方法将 top-5 定位错误率降低到了 10.6%（表 13）。这是我们在验证集上的单模型结果。通过同时对分类和定位任务使用网络集成（ensemble），我们在测试集上达到了 9.0% 的 top-5 定位错误率。该结果明显优于 ILSVRC 2014 的结果（表 14），错误率相对降低了 64%。这一结果使我们在 ILSVRC 2015 的 ImageNet 图像定位任务中获得了第一名。

