

任务类型	损失函数	数学核心 / 公式思想	适用场景	关键注意事项
分类	Binary Cross Entropy (BCE)		二分类、多标签分类	预测值需在(0,1); 搭配Sigmoid; 推荐用 <code>BCEWithLogitsLoss</code> 保数值稳定
分类	Cross Entropy (CE)		多分类 (互斥类别)	PyTorch版内含LogSoftmax, 输出层无需再加Softmax; 支持类别索引或one-hot标签
分类	Focal Loss		类别严重不平衡、目标检测	
分类	Label Smoothing CE		防过拟合、提升泛化与概率校准	
分类	KL Divergence	衡量两概率分布差异	知识蒸馏、分布匹配	非对称; 通常作正则项辅助主损失, 不单独使用
分类	Hinge / SVM Loss		最大间隔分类、少样本学习	对异常值鲁棒; 不直接输出概率, 需额外校准
回归	MSE (L2)		通用回归 (默认首选)	对大误差敏感 (平方放大); 假设误差服从高斯分布
回归	MAE (L1)		存在离群点、需稳健估计	梯度恒定不受极端值影响; 零点不可导 (框架自动处理)
回归	Huber / Smooth L1	小误差用MSE, 大误差切MAE	兼顾精度与鲁棒性	
回归	Log-Cosh		Huber的平滑替代	
回归	Quantile Loss	对不同分位数施加不对称惩罚	区间预测、不确定性估计	可同时训练多个分位数头, 输出完整预测区间
生成/特殊	GAN Minimax Loss	生成器与判别器对抗博弈	图像生成、数据增强	训练不稳定, 需精细调参; 关注模式崩塌问题

任务类型	损失函数	数学核心 / 公式思想	适用场景	关键注意事项
生成/特殊	VAE ELBO	重建损失 + KL散度正则	变分自编码器、隐空间建模	KL项权重需平衡，避免后验坍塌或重建模糊
生成/特殊	Perceptual Loss	预训练VGG特征空间距离	超分辨率、风格迁移	比像素级MSE更符合人类感知；依赖预训练模型
生成/特殊	Contrastive / InfoNCE	拉近正样本对，推远负样本对	自监督学习、表示学习 (CLIP/SimCLR)	负样本数量直接影响性能；温度系数 τ 需调优
生成/特殊	CTC Loss	对所有可能对齐路径求和	语音识别、OCR (序列不对齐)	无需逐帧标注；输入长度必须 $\geq$ 标签长度

