

类别	代表机制	核心原理 / 计算方式	作用 维度	复 杂 度	典型应用场景	关键特点与局限
基础 范式	Self- Attention	Q-K-V 点积 + Softmax + 加权 V	序列 内部 全局		Transformer 编码 器/解码器	捕获任意长程依 赖；但计算与内存 开销随序列长度平 方增长
	Cross- Attention	Q 来自目标序列，K/V 来自源序列	跨序 列对 齐		机器翻译、多模态生 成	实现条件生成与信息 融合；需两个对 齐的信息源
	Multi-Head Attention	将 Q/K/V 分割为 h 个 子空间并行计算	多维 特征 子空 间		几乎所有现代 Transformer	多头学习不同模式 (语法/语义/位 置)；是基础注意 力的标配扩展
因果 与控 制	Causal / Masked Attention	Self-Attention + 下三 角掩码矩阵	序列 时间 方向		GPT 等自回归语言 模型	防止未来信息泄 露；训练与推理行 为一致
	Padding Mask Attention	屏蔽填充符对应的 K/V 位置	Batch 内有 有效 长度		变长序列 Batch 训 练	避免无意义 padding 参与计 算；工程实现必备
	Flash Attention	IO 感知分块计算 + 重 物质化	全局 (精 确等 价)		LLM 训练/推理加速	数学结果完全等 价；训练加速 2- 4x，已成为事实标 准
效率 优化	GQA / MQA	多个 Q 头共享少量 K/V 头	多头 KV Cache		Llama-3, Qwen-2 等 开源 LLM	推理内存显著降 低；模型质量损失 极小
	Sparse Attention	仅计算局部窗口/全局 锚点/随机模式	稀疏 子集		Longformer, BigBird	突破二次复杂度； 但对非结构化长程 依赖可能失效
	Linear Attention		全局 (近 似)		Performer, RetNet	线性复杂度；近似 误差可能导致生成 质量下降
CNN 特征 注意 力	CBAM	通道(Avg+Max+MLP) → 空间 (Pool+Conv+Sigmoid) 串联	通道 + 空间		ResNet/EfficientNet 等 CNN	即插即用、代价极 低；纯 CNN 骨干性 价比最高的注意力 增强
	SE-Net	全局平均池化 + 两层 MLP + Sigmoid	仅通 道		图像分类骨干网络	开创通道注意力先 河；忽略空间信 息，表达力弱于 CBAM
	SK-Net	多尺度分支 + GAP + Softmax 选择	多尺 度通 道		细粒度识别、目标检 测	自适应感受野；计 算量高于 SE/CBAM

类别	代表机制	核心原理 / 计算方式	作用维度	复杂度	典型应用场景	关键特点与局限
结构增强	RoPE	旋转矩阵将位置编码注入 Q/K 向量	相对位置		Llama, Qwen, GPT-NeoX	天然支持相对位置与长度外推；当前 LLM 位置编码事实标准
	Relative Positional Encoding	注意力分数中加入可学习的相对距离偏置	相对位置		T5, DeBERTa	泛化到未见长度优于绝对编码；实现比 RoPE 稍复杂
替代范式	State Space Models (Mamba/S4)	线性状态空间方程替代注意力	序列全局状态		超长序列建模、音频处理	线性复杂度且支持并行训练；精确回忆与复杂推理仍弱于 Transformer
	Test-Time Compute Scaling	推理时动态分配更多注意力计算步骤	推理时思维链	推理时动态增长	o1/o3 类推理模型	不改预训练架构，通过推理规模提升复杂任务表现；推理成本显著增加