

ACL IMDb 情感二分类实验

0.总体架构

Part 1: 数据统计与预处理

- 1.原始数据集重新划分（原始训练集25k→训练集20k+验证集5k）
- 2.(对实际训练集20k)清洗/小写/分词 → 长度统计 → 词频统计→ 可视化输出（确定超参数 MAX_LEN / MAX_VOCAB）
- 3.编码（含第二排序） → 保存产物文件

Part 2: 模型训练

- 4.确定其它超参数
- 5.加载预处理产物 → 分别训练 3 种架构 → 对比评估
- Model A: UniLSTM (hidden=64, output=64) ← 基线
- Model B: UniLSTM (hidden=128, output=128) ← 单向加宽
- Model C: BiLSTM (hidden=64, output=128) ← 双向拼接

1.实验概述

项	内容
数据集	ACL IMDb 电影评论情感分类数据集（50,000 条）
数据划分	原始训练集 25k → 训练集 20k + 验证集 5k （分层抽样划分）；测试集 25k（完全不可见）
对比模型	3 种 LSTM 架构
任务类型	二分类（Positive / Negative）
核心原则	数据隔离：所有统计量仅基于 20k 训练集计算

对比设计：

模型	架构	Hidden Size (每方向)	方向	FC 输入维度
A（基线）	2-Layer UniLSTM	64	单向	64
B（单向加宽）	2-Layer UniLSTM	128	单向	128
C（双向拼接）	2-Layer BiLSTM	64	双向	128 (=64×2)

对比目的：

- **A vs B**：判断增加 hidden size 能否提升性能（容量效应）

- **B vs C**: 判断相同参数量、相同输出维度下，双向结构是否优于单向加宽（结构效应）
- **A vs C**: 判断双向结构带来的总提升有多少（综合效应）

2.Part 1 数据统计与预处理

2.1 流程总览



2.2具体设计

Step1~3

- [Step 1] 清洗 HTML 标签（正则）
- [Step 2] 小写化 `text.lower()`
- [Step 3] 正则分词（单词 + 标点独立切分）

Step 4（仅基于 20k 训练集）

统计输出以下指标：

统计量
最小值 (min)
中位数 (median)
平均数 (mean)
90% 分位数
95% 分位数
最大值 (max)

- **可视化**：长度分布直方图 + 箱线图+不同 `MAX_LEN` 下的样本覆盖率曲线

- **决策规则**：参考 95% 分位数 + 覆盖率拐点，确定 `MAX_LEN`
- **截断策略**：头部截断
- **填充策略**：末尾用 `<PAD>` (ID=0) 填充至 `MAX_LEN`

Step 5（仅基于 20k 训练集）

- 统计所有 Token 词频，按降序排列
- 计算累积 Token 覆盖率
- 可视化
- 找到 90%、95% 覆盖率对应的词表大小
- 结合拐点确定 `MAX_VOCAB`

Step 6

- **整数编码**

特殊 Token	ID
<code><PAD></code>	0
<code><UNK></code>	1

- **排序规则**：

第一排序：词频**降序**

第二排序：同频词按**字典序 (a-z) 升序**（保证编码确定性）

ID从2开始往后排

- **编码范围**：

20k 训练集 → 正常编码

之后5k 验证集 / 25k 测试集中出现的、但在训练集词表中不存在的词，必须全部替换为 ID=1 ()

3.Part 2 模型训练

3.1 统一超参数配置

三种模型超参数：

超参数	值	说明
Embedding Dim	128	三模型统一
Batch Size	64	20k 样本推荐值
Optimizer	Adam	lr = 0.001

超参数	值	说明
Grad Clip Norm	1.0	L2 范数裁剪阈值，防梯度爆炸
Dropout	0.5	LSTM 层间
Epochs	30	最大训练轮数
Early Stopping	监控 Val_F1	patience=5，无提升则终止
Loss Function	BCEWithLogitsLoss	内置数值稳定的 Sigmoid
Random Seed	42	全局固定

3.2训练策略

3.2.1 批次规划

项	值
训练集大小	20,000 条
每轮步数	$\lceil 20000/64 \rceil = 313 \text{ 步/Epoch}$
日志频率	每 31 批 (约 10% Epoch) 打印一次

3.2.2 损失计算规范

- 1. 序列打包：使用 pack_padded_sequence 使LSTM跳过PAD位置的计算，确保最后时刻隐藏状态仅由真实Token产生
- 2. 尾批处理：最后一批不足64条时，Loss按实际样本数计算平均

4.训练日志输出规范

4.1 训练批次日志（每 31 批触发）

[A_UniLSTM_64] [Train] Epoch: [03/30] Batch: [093/313] Loss: 0.4523 Acc: 79.25% Grad_Norm: 0.82 LR: 1.0e-3 Time: 12.3s
--

4.2 验证集评估日志（每 Epoch 结束触发）

[A_UniLSTM_64] [Eval] Epoch: [03/30] Val_Loss: 0.3891 Val_Acc: 82.45% Val_F1: 0.821 Best_F1: 0.835 (Ep02) LR: 1.0e-3
--

4.3 Early Stopping 触发日志

```
[A_UniLSTM_64] [Stop] Early Stopping at Epoch 18. Best Val_F1: 0.862 (Epoch 13).  
Restoring best weights.
```

5.评估指标体系

5.1 指标定义

指标	说明	用途
Accuracy	准确率	基础监控
Loss (BCE)	Binary Cross Entropy	优化目标
Precision	精确率	正类识别能力
Recall	召回率	正类覆盖能力
F1-Score	调和均值	Early Stopping 依据
AUC-ROC	曲线下面积	排序能力评估

5.2 单模型测试集报告（每个模型各一份）

```

===== Final Test Report =====
Model: A_UniLSTM_64
Test Accuracy : 89.96%
Test F1-Score : 0.902
Test AUC-ROC  : 0.963

Confusion Matrix:
                Predicted Neg  Predicted Pos
Actual Neg      10950          1550
Actual Pos       959          11541
=====

===== Final Test Report =====
Model: B_UniLSTM_128
Test Accuracy : 90.25%
Test F1-Score : 0.903
Test AUC-ROC  : 0.963

Confusion Matrix:
                Predicted Neg  Predicted Pos
Actual Neg      11192          1308
Actual Pos      1129          11371
=====

===== Final Test Report =====
Model: C_BiLSTM_64
Test Accuracy : 89.92%
Test F1-Score : 0.903
Test AUC-ROC  : 0.964

Confusion Matrix:
                Predicted Neg  Predicted Pos
Actual Neg      10811          1689
Actual Pos       831          11669
=====

```

5.3 三模型对比总报告

===== Model Comparison Report =====						
Model	Test Acc	Test F1	Test AUC	Params	Best Ep	Train Time
A: UniLSTM-64	89.96%	0.902	0.963	1,216,705	28	14.8 min
B: UniLSTM-128	90.25%	0.903	0.963	1,398,017	25	15.0 min
C: BiLSTM-64	89.92%	0.903	0.964	1,332,481	20	27.9 min
Pairwise Comparison:						
B vs A (容量效应): Acc +0.29%, F1 +0.001						
C vs B (结构效应): Acc -0.33%, F1 -0.001						
C vs A (综合效应): Acc -0.04%, F1 +0.001						

5.4优化（控制参数量）

实验组B和C的参数量相差较大，根据实验组B和C的结果，控制B和C为相等的参数量，进一步判断参数量对训练效果的影响

组件	Model B2（新 UniLSTM）	Model C2（原 BiLSTM）	差异
架构	2-Layer UniLSTM + FC隐藏层	2-Layer BiLSTM	—
Hidden Size	106	64	—
FC 结构	106 → 74 → 1	128 → 1	—
LSTM 第1层	4×(128+106+2)×106=100064	4×(128+64+2)×64×2=99,328	+736
LSTM 第2层	4×(106+106+2)×106=90,736	4×(128+64+2)×64×2=99,328	-8,592
FC 层	106×74+74+74×1+1=7993	128×1+1=129	+7,864
总计（不含 Emb）	198,793	198,785	+8 (+0.004%)

```

===== Final Test Report =====
Model: B2_UniLSTM_106 (UniLSTM H=106 + FC(106→74→1))
Test Accuracy : 90.26%
Test F1-Score : 0.901
Test AUC-ROC : 0.964

Confusion Matrix:
                Predicted Neg  Predicted Pos
Actual Neg      11536           964
Actual Pos      1471           11029
=====

===== Final Test Report =====
Model: C2_BiLSTM_64 (BiLSTM H=64 + FC(128→1))
Test Accuracy : 90.56%
Test F1-Score : 0.906
Test AUC-ROC : 0.965

Confusion Matrix:
                Predicted Neg  Predicted Pos
Actual Neg      11267           1233
Actual Pos      1128           11372
=====

```

在参数量相等情况下，双向效果高于两个单向